Impacto de morfemas na segmentação de grandes modelos de linguagem para o português brasileiro

Guilherme Lamartine de Mello

Dissertação apresentada ao
Instituto de Matemática, Estatística e
Ciência da Computação da Universidade de São Paulo
para obtenção do título de
Mestre em Ciências

Programa: Ciência da Computação
Orientador: Prof. Dr. Marcelo Finger

Durante o desenvolvimento deste trabalho o autor recebeu auxílio financeiro de
USP-IBM-FAPESP Center for Artificial Intelligence (C4AI), FAPESP – processo nº 2019/07665-4

São Paulo
Abril de 2026

Impacto de morfemas na segmentação de grandes modelos de linguagem para o português brasileiro

Guilherme Lamartine de Mello

Esta versão da dissertação contém
as correções e alterações sugeridas
pela Comissão Julgadora durante a
defesa da versão original do trabalho,
realizada em 2 de Abril de 2026.

Uma cópia da versão original está
disponível no Instituto de Matemática,
Estatística e Ciência da Computação
da Universidade de São Paulo.

Comissão julgadora:

Prof. Dr. Marcelo Finger (orientador) – IME-USP
Prof. Dr. Thiago Alexandre Salgueiro Pardo – ICMC-USP
Dr. Paulo Rodrigo Cavalin – IBM

O conteúdo deste trabalho é publicado sob a licença CC BY 4.0
(Creative Commons Attribution 4.0 International License)

Ficha catalográfica elaborada com dados inseridos pelo(a) autor(a)
Biblioteca Carlos Benjamin de Lyra
Instituto de Matemática, Estatística e Ciência da Computação
Universidade de São Paulo

Mello, Guilherme Lamartine de
Impacto de morfemas na segmentação de grandes modelos de linguagem para o português brasileiro / Guilherme Lamartine de Mello; orientador, Marcelo Finger. - São Paulo, 2026.
70 p.

Dissertação (Mestrado) - Programa de Pós-Graduação em Ciência da Computação / Instituto de Matemática, Estatística e Ciência da Computação / Universidade de São Paulo.
Bibliografia
Versão corrigida

1. Processamento de Linguagem Natural. 2. Redes Neurais Profundas. 3. Segmentação. 4. Português Brasileiro. I. Finger, Marcelo. II. Título.

Bibliotecárias do Serviço de Informação e Biblioteca
Carlos Benjamin de Lyra do IME-USP, responsáveis pela
estrutura de catalogação da publicação de acordo com a AACR2:
Maria Lúcia Ribeiro CRB-8/2766; Stela do Nascimento Madruga CRB 8/7534.

Resumo

Guilherme Lamartine de Mello. **Impacto de morfemas na segmentação de grandes modelos de linguagem para o português brasileiro**. Dissertação (Mestrado). Instituto de Matemática, Estatística e Ciência da Computação, Universidade de São Paulo, São Paulo, 2026.

Modelos de segmentação em nível de sub-palavras como *Byte Pair Encoding* (Sennrich *et al.*, 2016), *Unigram* (Kudo, 2018) e *WordPiece* (Schuster e Nakajima, 2012), permitem o tratamento de problemas de vocabulário aberto utilizando um conjunto relativamente pequeno de segmentos. Embora esses algoritmos sejam fáceis de utilizar e escalar, por serem abordagens baseadas exclusivamente em dados, acabam deixando de lado características linguísticas ou morfológicas durante a construção do vocabulário e no processo de segmentação de textos. Bostrom e Durrett, 2020 e Hofmann *et al.*, 2021 mostram que a presença de morfemas impacta positivamente a performance de grandes modelos de linguagem para o Inglês. Desta forma, este trabalho explora a hipótese de que um maior alinhamento do processo de segmentação como uma sequência de morfemas pode melhorar a capacidade de generalização de LLMs para o Português. Para isso, é proposto um método de avaliação, chamado MorphEval-PT, utilizado para medir a capacidade dos segmentadores em produzir segmentos morfologicamente coerentes, que busca incorporar conceitos psicolinguísticos de processamento morfológico. Diferentes algoritmos de segmentação são utilizados para o pré-treinamento de novos modelos de linguagem a fim de relacionar os resultados obtidos no MorphEval-PT com a performance em tarefas subsequentes. De forma consistente, o BPE mostrou uma melhor precisão que o *Unigram* na capacidade de representar morfemas, além de melhores resultados nas tarefas de avaliação conjunta. Esses resultados apresentam fortes evidências de que a capacidade de gerar segmentos morfologicamente coerentes é uma característica importante a ser considerada durante o desenvolvimento de LLMs para o Português Brasileiro.

Palavras-chave: Processamento de Linguagem Natural. Segmentação. Português Brasileiro. *Transformers*.

Abstract

Guilherme Lamartine de Mello. **Impact of morphemes on tokenizers of large language models for brazilian portuguese.**. Thesis (Master's). Institute of Mathematics, Statistics and Computer Science, University of São Paulo, São Paulo, 2026.

Sub-word level tokenizers, such as *Byte Pair Encoding* (Sennrich *et al.*, 2016), *Unigram* (Kudo, 2018) and *WordPiece* (Schuster and Nakajima, 2012), allow for the handling of open vocabulary problems using a relative small set of tokens. Although they are easy to use and scale, they rely on a data-driven approach and do not use any linguistic or morphologic feature when building its vocabulary or during text tokenization. Bostrom and Durrett, 2020 and Hofmann *et al.*, 2021 demonstrate that morphemes improves large language models performance on English texts. In this work, we explore the hypothesis that a tokenization with a better morpheme alignment can improve LLM performance on Brazilian Portuguese. For that, MorphEval-PT, a new evaluation procedure based on the psycholinguistic concept of morphological model of word processing, is proposed to measure how morphological coherent is a sequence of tokens. Different tokenization algorithms are used to pre-train new language models in order to relate the results obtained by MorphEval-PT with downstream tasks performance. Consistently, BPE demonstrated better precision than *Unigram* in its ability to represent morphemes, as well as better results on downstream tasks. These results show strong evidences that the ability to generate a morphological coherent sequence of tokens is an important feature to be considered when developing LLMs for Brazilian Portuguese.

Keywords: Natural Language Processing. Tokenizer. Brazilian Portuguese. *Transformers*.

Lista de tabelas

4.1 MorphyNet: Tamanho da base disponibilizada para o Português em cada processo de formação de palavras. *Formas* representa o total de entradas. *Palavras* é o número de palavras únicas, utilizadas como base do processo de formação de palavras. *Morfemas* é o número de morfemas diferentes utilizados para transformar a palavra base. 22

4.2 Exemplo de flexões presentes na MorphyNet. 23

4.3 Exemplo de Derivações presentes na MorphyNet. 23

4.4 Exemplo de palavras filtradas pelo corretor ortográfico. As formas flexionadas e derivadas apresentam seus afixos em negrito. 24

4.5 Informações sobre a construção da base de avaliação e quantas entradas foram removidas em cada filtro. "Sem Morfemas" representa as entradas que não disponibilizam uma segmentação de morfemas, "Palavras Inválidas" correspondem às palavras não identificadas pelo corretor ortográfico e "Morfemas Inválidos" representam entradas em que a sequência de morfemas não permite a reconstrução da forma flexionada/derivada. 26

4.6 Ao todo, foram obtidos 388 afixos de derivação (188 prefixos e 200 sufixos) e 162 sufixos de flexão. São apresentados os 10 afixos mais frequentes, nos dados gerados, para cada caso, juntamente com com suas frequências absolutas. 27

4.7 Os casos apresentados na parte superior mostram que é possível identificar afixos não segmentados ao avaliar a segmentação da base da palavra complexa. Os casos exemplificados na parte inferior mostram que alguns casos podem ser redundantes. 28

4.8 Tamanho e número de instâncias de cada taxonomia presente no Corpus Carolina. Os dados apresentados referem-se à versão 2.0.1. 32

4.9 Distribuição dos dados dos corpus ASSIN e ASSIN 2. 33

4.10 Distribuição dos dados do corpus HateBR por nível de anotação. 33

4.11 Distribuição dos dados do HateBR para a tarefa de detecção de linguagem ofensiva. 34
4.12 Distribuição dos dados do HateBR para a tarefa de detecção de discurso de ódio 34

5.1 Avaliação na base de derivações. Total de palavras: 11501. 39
5.2 Avaliação na base de flexões. Total de palavras: 299807. 40
5.3 Estatísticas sobre a presença de afixos no vocabulário de cada segmentador. Os valores estão separados entre os tipos de afixos. Ao todo, os dados derivados da MorphyNet apresentam 162 sufixos de flexão e 388 afixos de derivação, sendo 188 prefixos e 200 sufixos, resultando em 550 afixos diferentes. 42
5.4 Resultados obtidos para as tarefas de inferência textual (RTE) e similaridade (STS) das bases ASSIN e ASSIN 2, respectivamente medidas com Score F1 e a correlação de Pearson. 44
5.5 Resultados obtidos para as tarefas de detecção de linguagem ofensiva e detecção de discurso de ódio do HateBR, ambas medidas com F1. 45

Sumário

1 Introdução **1**
1.1 Motivação . . . 1
1.2 Hipótese de Pesquisa . . . 3
1.3 Objetivos . . . 4

2 Revisão Bibliográfica **5**

3 Conceitos Teóricos **11**
3.1 Morfologia . . . 11
3.1.1 Formação de Palavras . . . 12
3.1.2 Léxico Mental . . . 14
3.2 Modelos de Segmentação (*tokenizers*) . . . 15
3.2.1 *WordPiece* . . . 16
3.2.2 *Byte Pair Enconding* . . . 17
3.2.3 *Unigram* . . . 18
3.3 Arquitetura *Transformers* . . . 19
3.3.1 Qwen . . . 19

4 Métodos **21**
4.1 MorphEval-PT: Avaliando segmentos morfologicamente coerentes . . . 21
4.1.1 MorphyNet . . . 21
4.1.2 Filtragem e Transformação . . . 24
4.1.3 Limitações . . . 26
4.1.4 Métricas de Avaliação . . . 28
4.2 Corpus de Pré-Treinamento . . . 31
4.2.1 Corpus Carolina . . . 31
4.3 Avaliação Conjunta . . . 32
4.3.1 ASSIN e ASSIN 2 . . . 32
4.3.2 HateBR . . . 33

5 Experimentos **35**
5.1 Avaliando a presença de segmentos semânticos 35
5.1.1 Modelos de Segmentação 36
5.1.2 Resultados 37
5.2 Impacto de Segmentos Semânticos 41
5.2.1 Qwen-PT: Pré-Treinamento de Modelos de Linguagem 41
5.2.2 Resultados: Avaliação Conjunta 43
5.2.3 HateBR 44

6 Conclusão **47**

Referências **49**

Capítulo 1

Introdução

1.1 Motivação

Nos últimos anos, os avanços na área de Processamento de Linguagem Natural tem utilizado modelos de linguagem natural baseados na arquitetura *Transformer* (Vaswani *et al.*, 2017), melhorando consideravelmente os resultados em tarefas como tradução, sumarização e classificação (Devlin *et al.*, 2018). Um dos motivos da eficiência desse tipo de modelo deve-se à sua capacidade de aprender representações linguísticas sem a necessidade de conhecimento sobre uma tarefa específica. Para isso, o treinamento desses modelos de linguagem é dividido em duas etapas: pré-treinamento e ajuste fino. Durante o pré-treinamento, as representações linguísticas são aprendidas por métodos de treinamento semissupervisionado, onde o próprio texto de entrada é utilizado para definir a saída. Somente na etapa de ajuste fino, utilizando métodos de treinamento supervisionado, o modelo será treinado para sua aplicação final.

Diferentes métodos de segmentação (*tokenization*) podem ser utilizados para que o texto de entrada seja compreendido pelo modelo de linguagem. A divisão do texto pode ocorrer em nível de palavras, sub-palavras ou caracteres, e o conjunto de segmentos (*tokens*) que o modelo é capaz de reconhecer forma o seu vocabulário. Embora a definição do que caracteriza uma palavra possa mudar de aplicação para aplicação (Jurafsky e Martin, 2024), a segmentação em nível de palavras pode apresentar alguns desafios para línguas que não apresentam uma separação clara, como é o caso do Chinês e do Japonês, onde não existem espaços em branco separando as palavras. Outro problema decorrente dessa abordagem é a necessidade de um vocabulário muito extenso e a presença considerável de palavras desconhecidas. As abordagens em nível de sub-palavras e caracteres aliviam esses problemas e, mesmo com o uso de um conjunto pequeno e de tamanho fixo, permitem a construção de um vocabulário aberto pela concatenação de seus elementos.

Embora os algoritmos em nível de caracteres permitam a construção de um vocabulário compacto, acabam transformando o texto de entrada em uma sequência muito grande de segmentos, dificultando o treinamento de novos modelos. Os algoritmos em nível de sub-palavra surgem como um ponto intermediário entre os dois outros níveis, permitindo que caracteres, sub-palavras e palavras sejam incluídas no vocabulário. Desta forma, algoritmos

em nível de sub-palavras apresentam um balanceamento ao combinar a flexibilidade de um vocabulário aberto com a representação do texto em uma sequência não muito extensa de segmentos. Por conta dessas características, os algoritmos de segmentação em nível de sub-palavras mostraram-se opções mais adequadas para o treinamento de grandes modelos de linguagem.

Mesmo que os algoritmos de segmentação em nível de sub-palavras sejam eficientes na redução do tamanho do vocabulário e permitam um melhor tratamento de palavras raras e desconhecidas, ainda são algoritmos baseados apenas em padrões estatísticos (*data driven*). Como consequência, acabam gerando muitos segmentos que não carregam informações gramaticais ou semânticas. Por exemplo, a segmentação morfológica da palavra *gostosas* é `gost|os|a|s`, com cada morfema carregando os respectivos significados: *apreciar + dotado de + feminino + plural*. Já a palavra *gostosuras* é formada pelos morfemas `gost|os|ura|s`, que possuem os significados *apreciar + dotado de + condição de + plural*. Porém, ao considerar o modelo BERT[1] multilinguístico obtemos as segmentações `go|stos|as` e `go|stos|uras`. Embora o modelo BERT multilinguístico tenha aprendido uma representação semelhante entre as duas palavras, estes segmentos não carregam significados alinhados aos significados dos morfemas. Além disso, os segmentos podem aparecer em palavras de significado completamente distinto, como é o caso do segmento `go`, que aparece na sequência `go|i|ânia`. Apesar do modelo identificar a recorrência do segmento `go`, esta recorrência não apresenta uma informação linguisticamente relevante, dificultando o processo de aprendizado do modelo.

Bostrom e Durrett (2020) mostram como segmentos que se assemelham com morfemas podem impactar nos resultados e concluem que o *Unigram* é um algoritmo mais eficiente do que o *Byte Pair Encoding* (BPE) nesse sentido. Outros trabalhos também apontam para os benefícios da presença de segmentos morfologicamente coerentes e, consequentemente, nos resultados gerados. Li *et al.* (2019) mostram que a segmentação em caracteres é suficiente para o Chinês, onde os caracteres já possuem um bom valor semântico. Porém, Kudo (2018) mostra que a segmentação em nível de sub-palavras é uma opção mais adequada para o Japonês, língua na qual a presença de afixos altera o significado de uma palavra e expande o valor semântico além do nível de caracteres. Desta forma, o processo de segmentação torna-se uma etapa muito relevante para o treinamento dos grandes modelos de linguagem (LLMs - *Large Language Models*), influenciando diretamente o aprendizado e a construção de representações internas do modelo.

Hofmann *et al.* (2021) fazem uma análise mais profunda sobre a influência do processo de segmentação na capacidade de interpretação de palavras complexas em LLMs, considerando o Inglês como língua de estudo. Para isso, eles tomaram como base teorias psicolinguísticas que buscam explicar como o cérebro humano é capaz de atribuir significado para palavras complexas presentes no léxico mental (Plag, 2018; Leminen *et al.*, 2019). Modelos psicolinguísticos de processamento morfológico consideram dois tipos de mecanismos: armazenamento (*storage* ou *whole-word*) e decomposição (*computation* ou *decomposition*). No caso do mecanismo de armazenamento, o significado de uma palavra complexa é armazenado como uma única unidade no léxico mental, facilitando a recuperação de seu significado. No mecanismo de decomposição, o significado de uma palavra

[1] Disponível em https://huggingface.co/google-bert/bert-base-multilingual-cased

complexa é computado a partir da combinação dos significados de seus morfemas, que são as menores unidades semânticas. O que influencia a preferência entre um mecanismo ou outro é a frequência com que a palavra complexa é recuperada do léxico mental. Palavras utilizadas com frequência são recuperadas de forma mais eficiente quando processadas pelo mecanismo de armazenamento. Já para palavras pouco utilizadas, é mais eficiente recuperar seus significados a partir da combinação de seus morfemas. O mesmo vale para a atribuição de significado a palavras desconhecidas, permitindo inferir algum tipo de significado a partir dos morfemas conhecidos.

Evitando uma segmentação baseada exclusivamente em padrões estatísticos, Hofmann *et al.* (2021) relacionam essa teoria com a forma como LLMs interpretam e armazenam o significado de palavras complexas em seus pesos a partir dos segmentos de entrada. Assim como Kudo (2018) mostra, com o mesmo vocabulário, é possível gerar mais de uma sequência de segmentos para o mesmo texto de entrada, que são interpretadas como sequências completamente diferentes pelos LLMs. Neste sentido, Hofmann *et al.* (2021) utilizam o modelo BERT (Devlin *et al.*, 2018) como base, mantendo os pesos e o vocabulário do modelo pré-treinado intactos, substituindo apenas o algoritmo de segmentação *WordPiece* por um algoritmo capaz de gerar segmentações linguisticamente mais precisas. Explorando a possibilidade de gerar diferentes segmentações e a derivação, um processo de formação de palavras, eles conseguiram utilizar apenas os morfemas que já estavam presentes no vocabulário do BERT para gerar segmentações linguisticamente mais precisas, quando possível, permitindo a criação de representações morfologicamente mais coerentes. Como resultado, conseguiram obter um ganho de performance em diversas tarefas subsequentes (*downstream tasks*) sem a necessidade de pré-treinamento ou ajuste-fino.

Para conseguir gerar essa segmentação, Hofmann *et al.* (2021) utilizaram alguns recursos linguísticos disponíveis para o Inglês, que permitiram substituir a representação de superfície de uma palavra pela sua representação mais profunda, criando uma segmentação sensível às alterações morfossintáticas, retornando o lema da palavra e seus afixos. O Português não dispõe de recursos linguísticos idênticos e prontos para esse tipo de segmentação. O mais próximo disso é o MorphyNet (Batsuren *et al.*, 2021), que possui uma listagem de palavras complexas e a segmentação em palavra canônica (lema) e afixos, indicando a presença de alguns prefixos ou sufixos, separando-as em processos de derivação e flexão. Embora não esteja em um formato pronto para uso, é o melhor recurso encontrado para avaliar a hipótese deste trabalho. Outros recursos semelhantes são os analisadores morfológicos baseados na Morfologia de Estados Finitos (Beesley e Karttunen, 2003). Port4Nooj (Mota *et al.*, 2016) e MorphoBr (Alencar *et al.*, 2018) são dois analisadores morfológicos que, a partir de uma palavra complexa, retornam o lema da palavra e uma sequência de siglas, indicando os processos de flexão que foram utilizados. Embora esses recursos sejam linguisticamente mais precisos, são mais complexos e não apresentam informações suficientes sobre os processos de derivação, limitando a avaliação da hipótese desta pesquisa.

1.2 Hipótese de Pesquisa

Embora os algoritmos de segmentação em nível de sub-palavras sejam eficientes no tratamento de vocabulários abertos, por utilizarem abordagens exclusivamente baseadas em

dados, conforme exemplificado na Seção anterior, deixam de lado informações morfológicas importantes que podem auxiliar na eficiência e na capacidade de generalização em LLMs. Assim, este trabalho explora a hipótese de que um maior alinhamento do processo de segmentação (*tokenization*) como uma sequência de morfemas pode melhorar a qualidade semântica e, consequentemente, a capacidade de generalização dos LLMs.

1.3 Objetivos

Objetivo principal: Avaliar se a presença de segmentos morfológicos influencia na capacidade de generalização de LLMs para o Português Brasileiro, correlacionando os resultados obtidos em diferentes tarefas subsequentes com a capacidade de seus segmentadores em gerar segmentos morfologicamente coerentes.

Objetivo específico:

- Propor o método MorphEval-PT para avaliar a presença de segmentos morfologicamente coerentes, tomando como base os modelos psicolinguísticos de processamento morfológico.

Capítulo 2

Revisão Bibliográfica

A área de Processamento de Linguagem Natural (PLN) sempre foi um tema central para a Inteligência Artificial, seja pelo seu papel na inteligência humana ou pela grande variedade de aplicações (Cambria e White, 2014). Compreendendo técnicas computacionais para a análise automática ou representação da língua humana, a área de PLN passou por algumas mudanças no foco e no estilo de suas pesquisas (Jones, 1994; Young *et al.*, 2018; Otter *et al.*, 2021). O uso de técnicas conexionistas começou a ser explorado ainda na década de 1980, impulsionado pela popularidade de técnicas de Aprendizado de Máquina, levando ao surgimento do Processamento Estatístico de Linguagem Natural, que se tornou o principal paradigma a partir da década de 1990 (Jones, 1994; Otter *et al.*, 2021).

A popularização do uso de modelos de Aprendizado Profundo teve início com o trabalho desenvolvido por Bengio *et al.* (2003), mostrando ser possível reduzir o efeito da maldição da dimensionalidade ao permitir que a própria rede aprendesse representações distribuídas de palavras, transformando vetores de alta dimensionalidade em uma representação de tamanho fixo. Em conjunto, a rede também foi capaz de aprender uma função de probabilidade para uma sequência de palavras, criando um modelo de linguagem. Collobert e Weston (2008) mostraram a utilidade do pré-treinamento dessas representações de palavras (*word embeddings*), criando a base para muitas abordagens atuais (Young *et al.*, 2018). Desta forma, os sistemas que antes eram baseados em características linguísticas explícitas (morfológicas, léxicas, sintáticas, semânticas, etc...) passaram a ser representados por redes neurais artificiais de ponta-a-ponta (Belinkov e Glass, 2019).

Entretanto, a consolidação dessas representações de palavras veio com o trabalho de Mikolov *et al.* (2013) ao apresentarem o *Word2Vec*, um método eficiente para o aprendizado de representações distribuídas de alta qualidade, permitindo que até mesmo operações algébricas pudessem ser realizadas sobre essas representações. Os métodos *GloVe* (Pennington *et al.*, 2014) e *ELMo* (Peters *et al.*, 2018) também ajudaram na consolidação das representações distribuídas. Enquanto o *Word2Vec* utilizava apenas uma janela como contexto de treinamento, Pennington *et al.* (2014) perceberam que era possível utilizar métodos de fatoração de matrizes para calcular estatísticas do corpus como um todo ao gerar representações distribuídas de alta qualidade. Com o modelo *ELMo*, ao utilizar redes LSTM bidirecionais, as representações de palavras passam a incorporar toda a sentença

como contexto e não apenas as palavras antecedentes.

Mesmo que as Redes Neurais Profundas já apresentassem bons resultados, elas eram limitadas a sequências de tamanhos previamente definidos e, consequentemente, não eram adequadas para o processamento de sentenças mais longas ou de tamanhos variados. Para superar essa limitação, Cho *et al.* (2014) e Sutskever *et al.* (2014) utilizaram Redes Neurais Recorrentes e introduziram a arquitetura *encoder-decoder* para a tradução automática, permitindo a codificação de sentenças de tamanhos distintos em vetores de tamanhos fixos. Enquanto o *encoder* era responsável por gerar a codificação – um vetor de tamanho fixo – a partir da sequência de entrada, o *decoder* era responsável por transformar essa codificação em uma sequência de saída, criando uma relação que traduzia uma sequência de entrada em uma sequência de saída sem a necessidade de definir um tamanho específico para elas.

Com o uso de arquiteturas *encoder-decoder*, o desafio passou a ser o processamento de sequências cada vez maiores. Com a capacidade de representação limitada ao tamanho de um único vetor, não era possível representar todas as informações presentes na sentença de entrada e a relação entre as palavras. Para superar essa limitação, surgiram diferentes mecanismos de Atenção Neural, estendendo as capacidades das arquiteturas *encoder-decoder* (Bahdanau *et al.*, 2015; Luong *et al.*, 2015). Esses mecanismos permitiram que, para cada elemento gerado pelo *decoder*, fosse possível selecionar quais informações (segmentos) da sequência de entrada eram importantes para segmento de saída, criando um alinhamento entre os elementos das sequências de entrada e saída. Em um sistema de tradução, isso significa escolher apenas as palavras necessárias para gerar a tradução correta.

Com os avanços na capacidade computacional e na disponibilidade de dados, as arquiteturas *encoder-decoder*, que até então não se mostravam escaláveis para o processamento de quantidades cada vez maiores de dados, eram limitadas pela impossibilidade de paralelização de sua estrutura recorrente. Pensando nisso, Vaswani *et al.* (2017) propuseram o modelo *Transformer*, uma arquitetura *encoder-decoder* que eliminou a rede recorrente e manteve apenas um mecanismo de auto-atenção neural (*self-attention*). Sem a estrutura de processamento recorrente, o modelo se mostrou extremamente paralelizável, permitindo utilizar de forma mais eficiente os recursos computacionais disponíveis e, consequentemente, processar maiores quantidades de dados.

Inspirados pelos avanços em Visão Computacional no uso de técnicas de Transferência de Aprendizado, Howard e Ruder (2018) mostraram ser possível aplicar tais conceitos na área de PLN ao apresentarem o método *ULMFit* (*Universal Language Model Fine-tuning*). Neste método, a Transferência de Aprendizado ocorre em três etapas: pré-treinamento, adaptação de domínio e ajuste fino. Durante o pré-treinamento, o modelo de linguagem utiliza grandes quantidades de dados não rotulados e de propósito geral, com o objetivo de ensinar à rede neural a distribuição de palavras de uma língua. O pré-treinamento torna-se, então, uma fase em que a rede neural aprende sobre conhecimentos gerais. A adaptação de domínio, embora pouco utilizada na prática, busca especializar o pré-treinamento do modelo para o domínio da tarefa final, continuando a fase de pré-treinamento com uma nova base de dados e ajustando-o para uma nova distribuição de dados. Os pesos desta rede pré-treinada são utilizados para inicializar a rede neural final, transferindo o conhecimento geral e do domínio que foi aprendido até então. Com a introdução de pequenas alterações na arquitetura, o modelo é ajustado para uma tarefa subsequente

(*downstream task*), necessitando de uma quantidade consideravelmente menor de dados rotulados. Embora o pré-treinamento demande muitos recursos, mostrou-se uma técnica extremamente útil e versátil, permitindo que o mesmo modelo pré-treinado seja ajustado para diversas tarefas, facilitando a expansão do estado-da-arte em múltiplas tarefas de uma única vez (Ruder *et al.*, 2019).

Utilizando apenas o *encoder* da arquitetura *Transformers* e o mascaramento de segmentos (MLM - *Masked Language Modeling*) como método de pré-treinamento, Devlin *et al.* (2018) conseguiram criar representações de palavras e sentenças que permitiram avançar consideravelmente o estado-da-arte em diversas aplicações de Compreensão de Linguagem Natural (NLU - *Natural Language Understanding*). Na mesma linha, Radford, Narasimhan *et al.* (2018) utilizaram apenas o *decoder* pré-treinado com o método CLM (*Causal Language Modeling*) para obter uma forma eficiente de avançar o estado-da-arte em tarefas de Geração de Linguagem Natural (NLG - *Natural Language Generation*). Os modelos BERT (Devlin *et al.*, 2018) e GPT (Radford, Narasimhan *et al.*, 2018) passam, então, a definir uma nova base para a área de PLN, que foca no desenvolvimento de modelos base (*foundation models*) para serem utilizados, posteriormente, em diversas aplicações por meio do ajuste-fino.

Com a consolidação dos modelos pré-treinados para transferência de aprendizado, diferentes métodos de pré-treinamento começaram a ser explorados (Otter *et al.*, 2021). Y. Liu *et al.* (2019) propuseram o método RoBERTa, uma forma mais extensa e otimizada de pré-treinamento do BERT, demonstrando a utilidade do uso de maiores quantidades de dados para o pré-treinamento. XLNet foi outro modelo que mostrou a utilidade de bases cada vez maiores, ao utilizar cerca de 33 bilhões de segmentos para treinamento. Além disso, outra tendência foi o desenvolvimento de modelos cada vez maiores, permitindo que os resultados pudessem ser melhorados de acordo com a escala utilizada (Kaplan *et al.*, 2020). Desta forma, modelos que inicialmente tinham pouco mais de 100 milhões de parâmetros, como BERT_{base} (Devlin *et al.*, 2018) e GPT (Radford, Narasimhan *et al.*, 2018), passaram a atingir tamanhos próximos a 175 bilhões de parâmetros a partir do GPT-3 (Brown *et al.*, 2020), chegando a mais de 670 bilhões com o DeepSeek-V3 (DeepSeek-AI *et al.*, 2025).

Devido aos custos computacionais exigidos para treinamento e, posteriormente, uso desses modelos, que se tornaram cada vez maiores, diferentes abordagens passaram a ser exploradas para melhorar esse cenário. Pensando no uso de LLMs em dispositivos menores, Sanh *et al.* (2019) apresentaram o DistilBERT, um método capaz de reduzir em 40% os parâmetros do BERT, retendo 97% de sua performance. Embora o DistilBERT permita o desenvolvimento de modelos menores, reduzindo o uso de memória e o tempo de inferência, ainda requer o uso de modelos maiores já pré-treinados, chamados de professores, necessários para guiar o treinamento dos modelos menores (alunos). Uma abordagem mais adequada, portanto, seria o desenvolvimento de métodos de pré-treinamento mais eficientes. Em substituição ao MLM, ao apresentarem o modelo ELECTRA, Clark *et al.* (2020) propuseram o RTD (*Replacement Token Detection*), um método mais eficiente que permitiu reduzir consideravelmente os custos computacionais para obter resultados semelhantes aos modelos de mesmo tamanho. Quando considerado o mesmo custo computacional, o modelo ELECTRA conseguiu superá-los consideravelmente. Para isso, o RTD utiliza um modelo pequeno como gerador e um modelo discriminador (principal) para detectar quais segmentos foram substituídos ou não.

Outros trabalhos buscaram melhorar a eficiência dos LLMs por meio de alterações na arquitetura *Transformer*. Neste sentido, Lan *et al.* (2019) propuseram o método ALBERT, utilizando técnicas para a redução de parâmetros, como a decomposição da matriz de *embedding* e o compartilhamento de parâmetros entre camadas. Desta forma, reduziram os requisitos computacionais e o tempo de treinamento do BERT, facilitando a escalabilidade do modelo e a obtenção de melhores resultados. Outro modelo que se destaca é o DeBERTa (He, X. Liu *et al.*, 2021), com alterações no mecanismo de atenção (*disentangled attention*), criando duas representações para cada segmento de entrada: um vetor para representar o conteúdo e outro para a posição. Posteriormente, os resultados foram melhorados com o DeBERTaV3 (He, Gao *et al.*, 2021), ao substituírem o MLM pelo RTD (Clark *et al.*, 2020). Porém, He, Gao *et al.* (2021) percebem que havia um problema (*tug-of-war*) com o RTD originalmente proposto e apresentam uma solução para o método de compartilhamento de parâmetros (*gradient-disentangled embedding sharing*) entre o discriminador e o gerador.

Sendo o mecanismo de atenção neural o componente central dos ganhos de performance apresentados pela arquitetura *Transformers* e, também, sendo um dos componentes que mais demanda poder computacional por apresentar uma complexidade de $O(N^2)$, diversos trabalhos acabaram apresentando diferentes soluções para permitir escalar a quantidade de contexto utilizado como entrada. Sun *et al.* (2025) apresentam duas categorias de métodos: lineares e esparsos. Dentre os métodos lineares, está, por exemplo, o uso de aproximações dos pesos de atenção pelo uso de funções de *kernel* para substituir a função *softmax*. Já os métodos esparsos buscam reduzir a complexidade computacional pela seleção de um subconjunto dos segmentos de entrada, por meio de heurísticas, por exemplo.

Outro requisito necessário para o pré-treinamento de grandes modelos linguísticos é a disponibilidade de dados e, assim como grande parte das técnicas de Aprendizado Profundo, a maioria das pesquisas foram direcionadas para o Inglês (Hedderich *et al.*, 2021). Entretanto, nem todas as línguas possuem os recursos necessários, caracterizando um cenário de baixa disponibilidade de recursos (Joshi *et al.*, 2020). Uma alternativa para este cenário é o uso de um corpora com textos de diferentes línguas para o treinamento de modelos multilinguísticos, possibilitando o uso de técnicas de Transferência de Aprendizado Cross-lingual (Conneau e Lample, 2019), como traduções *zero-shot* (Johnson *et al.*, 2017; T. Pires *et al.*, 2019).

Com o aumento da complexidade dos modelos, impulsionados pela lei de escala (Kaplan *et al.*, 2020), foi possível observar alguns comportamentos emergentes (Berti *et al.*, 2025). Modelos generativos como o GPT3 (Brown *et al.*, 2020) começaram a exibir comportamentos que não eram observados em modelos menores. Através de técnicas de engenharia de *prompt*, como *few-shot* e *chain-of-thought*, chamadas de *in-context learning*, foi possível observar uma melhora significativa na capacidade de raciocínio lógico e, consequentemente, nos resultados obtidos por LLMs em diferentes tarefas que exigiam tais competências. A grande vantagem dessas técnicas é a adaptação do modelo sem a necessidade de ajustar os parâmetros do modelo, como é feito durante o ajuste-fino do modelo.

Mesmo com essas técnicas, por sua natureza, o treinamento de LLMs ainda possui algumas limitações práticas. Por enxergarem apenas os fatos e as informações presentes nos dados de treinamento, LLMs facilmente se tornam desatualizadas e podem apresentar alucinações, um fenômeno caracterizado pela geração de respostas erradas, mas que

parecem plausíveis (Kalai *et al.*, 2025). Para contornar a necessidade de retreinamento constante desses modelos, o desenvolvimento de agentes de IA permitiram o uso de ferramentas e fazer buscas na web para obter informações mais atualizadas. Embora o treinamento possa direcionar o modelo para a geração de incertezas, o problema de alucinações ainda permanece em aberto.

Segundo Joshi *et al.* (2020), o Português é uma língua com grande potencial para acessar as tecnologias presentes no estado-da-arte de PLN. Embora a língua portuguesa possua uma boa quantidade de dados disponíveis, ainda não é comparável às línguas com maior disponibilidade (Corrêa, Sen *et al.*, 2025) e requer o desenvolvimento de recursos maiores e melhores, principalmente recursos rotulados para o uso de técnicas supervisionadas.

No contexto da língua portuguesa, uma das possibilidades é o uso de modelos multilinguísticos, como mBERT (Devlin *et al.*, 2018), XLM (Conneau e Lample, 2019), XLM-R (Conneau, Khandelwal *et al.*, 2020), mT5 (Xue *et al.*, 2021) e mDeBERTaV3 (He, Gao *et al.*, 2021). No entanto, modelos monolinguísticos tendem a apresentar resultados melhores quando treinados com quantidades suficientes de dados (Virtanen *et al.*, 2019; Corrêa, Falk *et al.*, 2024). Dentre os principais modelos desenvolvidos para o Português, a principal estratégia adotada assemelha-se à etapa de adaptação de domínio (Howard e Ruder, 2018). Assim, modelos pré-treinados são utilizados como ponto de partida, caracterizando um pré-treinamento continuado para o domínio da língua portuguesa.

Seguindo essa estratégia, Souza *et al.* (2020) apresentaram o BERTimbau, um dos primeiros modelos desenvolvidos para o Português Brasileiro, utilizando arquiteturas nos tamanhos *base* e *large*. Os modelos foram inicializados com os pesos do mBERT e do BERT em Inglês, respectivamente, com vocabulário e camada de *embedding* construídos do zero. Para o treinamento do BERTimbau, foi utilizado o corpus *brWac* (Wagner Filho *et al.*, 2018), caracterizando um pré-treinamento continuado. Seguindo a tendência de modelos cada vez maiores, a família de modelos Albertina apresentou resultados melhores (J. Rodrigues *et al.*, 2023; Santos, J. Rodrigues *et al.*, 2024). Novamente, o pré-treinamento continuado é caracterizado por utilizarem o DeBERTaV3 (He, Gao *et al.*, 2021) para inicializar o modelo antes do pré-treinamento, incluindo seu vocabulário original. Diferente dos outros *encoders* para o Português, a família de modelos Serafim (Gomes *et al.*, 2024) utilizou os modelos BERTimbau e Albertina como base para a criação de representações de sentenças para uso em agrupamento de textos e recuperação de informações utilizando buscas semânticas.

Entretanto, o pré-treinamento continuado nem sempre apresenta ganhos de desempenho. Com a família de modelos PeLLE (Mello *et al.*, 2024), é possível observar que, para modelos menores, o uso de modelos multilinguísticos e o pré-treinamento continuado nem sempre resultam em ganhos de performance quando comparado ao pré-treinamento de modelos puros. Resultados mistos também foram observados por Schuck *et al.* (2025), ao comparar modelos generativos em tarefas de análise de sentimentos, quando o pré-treinamento continuado é combinado com ajuste total de parâmetros. Porém, ao considerar o método LoRA (*Low-Rank Adaptation*) (Hu *et al.*, 2021) para o ajuste de parâmetros, modelos monolinguísticos apresentaram melhores resultados. Com a família TeenyTinyLlama de modelos monolinguísticos, Corrêa, Falk *et al.* (2024) apresentaram resultados melhores que os modelos multilinguísticos. Para isso, eles utilizaram uma base de dados com aproximadamente 6.2 bilhões de segmentos, combinando textos (60%) e instruções de

comportamento (40%) que o modelo deveria seguir, indicando que a quantidade de dados tem grande impacto, também, na adaptação de modelos multilinguísticos.

Além disso, também foram desenvolvidos alguns modelos para gerar textos em Português. A família de modelos Sabiá (R. Pires *et al.*, 2023) também utilizaram o pré-treinamento continuado como abordagem de treinamento, tomando como base o GPT-J (Wang e Komatsuzaki, 2021) com 6 bilhões de parâmetros e os modelos LLaMA (Touvron *et al.*, 2023) de 7 e 65 bilhões de parâmetros. Seguindo a mesma estratégia, Larcher *et al.* (2023) apresentaram o modelo Cabrita, baseado nos pesos do modelo OpenLLaMA de 3 bilhões de parâmetros (Geng e H. Liu, 2023), porém, com um novo vocabulário adaptado para o Português. Inicializados com os pesos do LLaMA 2 de 7 bilhões de parâmetros, Gervásio (Santos, Silva *et al.*, 2024) é outra família de modelos *decoder* que foi treinada para seguir instruções. A partir do desenvolvimento de uma nova base de dados (GigaVerbo), com mais de 200 bilhões de *tokens*, Corrêa, Sen *et al.* (2025) apresentaram a família de modelos Tucano, treinando arquiteturas LLaMA do zero.

Diferentes métodos de segmentação podem ser utilizados para que o texto seja processado por um modelo de linguagem, variando entre os níveis de palavras, sub-palavras e caracteres. Por conta da capacidade de tratar problemas de vocabulário aberto utilizando um vocabulário de tamanho fixo, os métodos de sub-palavras consolidaram-se no desenvolvimento de grandes modelos de linguagem. Em sua grande maioria, os modelos utilizam o *Byte Pair Encoding* (Sennrich *et al.*, 2016), um método de segmentação desenvolvido a partir de um algoritmo de compressão de dados de mesmo nome. Sua grande vantagem em relação aos outros métodos de segmentação, como *WordPiece* (Schuster e Nakajima, 2012) e *Unigram* (Kudo, 2018), está no uso de *bytes* como unidades mínimas, conhecido como *byte-level* BPE, uma técnica introduzida no desenvolvimento do GPT-2 (Radford, Wu *et al.*, 2019), eliminando a possibilidade de segmentos desconhecidos.

Embora esses algoritmos sejam eficientes na redução do tamanho do vocabulário e permitam um melhor tratamento de palavras raras e desconhecidas, eles são baseados apenas em padrões estatísticos, gerando um vocabulário com muitos segmentos que não carregam informações gramaticais ou semânticas. Bostrom e Durrett (2020) mostra como a presença de morfemas pode impactar os resultados e conclui que o *Unigram* é um algoritmo mais eficiente do que o BPE nesse sentido. Hofmann *et al.* (2021) faz uma análise mais profunda sobre a influência do processo de segmentação na capacidade de interpretação de palavras complexas em LLMs, considerando o Inglês como língua de estudo. Para isso, eles se basearam em teorias psicolinguísticas que buscam explicar como o cérebro humano é capaz de processar e armazenar o significado de palavras complexas em seu léxico mental (Plag, 2018; Leminen *et al.*, 2019) e exploraram o uso da derivação, um processos de formação de palavras, para melhorar a capacidade de interpretação dos LLMs. Sem a necessidade de pré-treinamento ou ajuste fino de modelos, Hofmann *et al.* (2021) alteraram somente o algoritmo de segmentação e utilizaram apenas os morfemas já presentes no vocabulário original do modelo BERT (Devlin *et al.*, 2018). Desta forma, foi possível induzir o modelo a consumir uma sequência de segmentos mais próxima de uma sequência de morfemas, permitindo criar melhores representações semânticas e facilitar o uso do mecanismo de composição para obter melhores resultados em tarefas subsequentes (*downstream tasks*).

Capítulo 3

Conceitos Teóricos

3.1 Morfologia

A palavra *morfologia* refere-se aos estudos relacionados às formas e pode ser utilizada em diferentes contextos. Na biologia, por exemplo, a morfologia refere-se às formas e estruturas dos organismos. Na linguística, área de interesse deste trabalho, a morfologia refere-se às formas das palavras, englobando a análise da estrutura interna das palavras e os processos responsáveis pela formação de novas palavras. Durante a análise de sua estrutura interna, uma palavra pode ser dividida em morfemas: as menores unidades linguísticas dotadas de expressão (forma) e conteúdo (significado) (Gonçalves, 2019). Ao utilizar a palavra *morfologia* como exemplo, é possível encontrar os elementos `[morf(o)]` e `[logia]`, que possuem origem no grego *morphé* (forma) e *logía* (estudo), respectivamente. Desta forma, o significado da palavra *morfologia* surge da união do significado de seus dois morfemas: estudo das formas. Esta noção de que o significado de uma palavra surge a partir da combinação do significado de suas partes corresponde à um dos principais conceitos explorados no decorrer deste trabalho.

Palavras representam unidades linguísticas e, mesmo sendo um dos principais conceitos presentes na morfologia, a literatura não apresenta um consenso a respeito de sua definição formal, que pode ser definida em função de suas características ortográficas, fonológicas, semânticas ou sintáticas (Plag, 2018). Os problemas relacionados à definição de palavras a partir de suas características ortográficas também surgem no contexto de Processamento de Linguagem Natural, onde a definição de palavra, embora um pouco mais concreta, pode mudar de acordo com a aplicação, mesmo ao considerar uma única língua (Jurafsky e Martin, 2024).

Uma palavra pode ser expressa de forma escrita ou falada, apresentando diferentes características. Ao considerar essas duas formas, a definição do que é uma palavra torna-se ainda mais complexa. Uma forma de evitar esse tipo de complicação é separar os conceitos entre vocábulo fonológico e vocábulo formal (Gonçalves, 2019). Um vocábulo fonológico representa uma unidade sonora presente na fala. Já um vocábulo formal aparece na escrita, representando uma unidade semântica correspondente a um item lexical. Por se tratarem de unidades distintas, podem não apresentar correspondências simétricas de um para um.

De forma geral, uma palavra possuí um conjunto de (a) significados; (b) propriedades sintáticas; (c) propriedades morfológicas; e (d) determinações de uso. (Gonçalves, 2019).

3.1.1 Formação de Palavras

O estudo da formação de palavras indica que elas podem ser decompostas em elementos menores. Na morfologia, esses elementos são chamados de morfemas e representam as menores unidades linguísticas capazes de carregar significado ou função dentro de uma estrutura semântica. Desta forma, quando os morfemas são utilizados para compor palavras maiores, eles dão origem a significados mais complexos. Portanto, a formação de palavras trata de palavras morfologicamente complexas, ou seja, aquelas que podem ser decompostas em unidades menores e de significados mais simples. Morfemas são entidades abstratas e sua realização ocorre por meio do morfe, entendido como representações fonológicas de um morfema, ou seja, uma cadeia fonética que não pode ser decomposta em constituintes menores com significado lexical ou gramatical (Gonçalves, 2019). Assim, um único morfema pode ser caracterizado por um ou vários morfes, um fenômeno linguístico chamado de alomorfia.

Ao considerar morfes como partes recorrentes de uma língua, o que os torna reutilizáveis é a sua pertinência semântica. Durante uma análise morfológica, considera-se o conhecimento dos falantes sobre a estrutura interna das palavras de sua língua, desconsiderando questões históricas (diacronia), se restringindo aos fatos e conhecimentos de um ponto de vista sincrônico ("aqui e agora"). Desta forma, casos como *alho* e *bugalho*, embora compartilhem uma parte recorrente, não correspondem a morfes por não existir uma relação semântica entre eles (segmentos opacos). O mesmo acontece com a palavra *camaleão*, que não possui relação semântica nem com *cama* nem com *leão*.

Um mecanismo importante, presente no conhecimento implícito dos falantes, é a composicionalidade. Esse mecanismo inconsciente permite aos falantes calcular e predizer o significado de uma palavra complexa a partir do significado de seus constituintes mais básicos. Essa interpretação de palavras complexas pode ocorrer mesmo que uma das partes seja opaca, mostrando que a frequência com que o falante encontra os termos é importante para a aquisição de significado. Para exemplificar esse ponto, Gonçalves (2019) utiliza palavras terminadas em *-ite*, que remetem aos significados de inflamação, anomalia ou patologia. Assim, palavras terminadas em *-ite* são transparentes em seus significados, mesmo que a base seja opaca. Ou seja, é possível induzir um significado para palavras terminadas em *-ite*, mesmo sem conhecer sua base.

Morfemas podem assumir 3 formas:

- **Morfemas Presos (*bound*):** só podem acontecer quando associados (presos) a outros morfemas;
- **Morfemas Livres (*free*):** podem ocorrer de forma isolada;
- **Morfemas Dependentes:** utilizado para tratar casos específicos do Português, como os clíticos. Assemelham-se às formas presas por não serem usadas de forma independente, mas permitem a intercalação de outras formas ou têm mobilidade posicional.

O *radical*, também chamado de morfema nuclear ou lexical, é o morfema que resulta após a remoção de todas as marcas de flexão e derivação de uma palavra, sendo sua forma original e irredutível, responsável pelo significado central de uma palavra. A *raiz* de uma palavra difere do radical por carregar uma perspectiva diacrônica, remetendo às suas origens. *Afixos* são morfemas presos que se unem ao radical, de acordo com restrições posicionais, para formar novas palavras.

Os principais afixos presentes na língua portuguesa são os prefixos e sufixos. Ao serem avaliados de forma isolada, não apresentam comunicação suficiente, pois seu significado surge ao serem combinados com uma base e, por isso, são chamados de formas presas. Dentre as diferenças presentes entre eles, a posição em que são realizados é apenas a diferença mais superficial. Para o Português, prefixos e sufixos podem apresentar algumas diferenças (Gonçalves, 2019) como:

- Classe gramatical: de forma geral, prefixos não possuem a capacidade de alterar a classe gramatical das bases, enquanto sufixos tendem a alterá-la. Exceções existem em ambos os casos, mas a raridade no caso dos prefixos ainda mantém a regra de que prefixos não são responsáveis pela alteração da classe da base;
- Gênero: enquanto prefixos não geram alterações de gênero, sufixos quase sempre definem o gênero da palavra resultante;
- Bases: prefixos são combinados com palavras e sufixos com radicais, sendo raros os casos em que se combinam com palavras. Desta forma, ao retirar um prefixo, normalmente o que resta é uma palavra, uma forma livre. Já os sufixos, quando retirados, resultam em uma forma presa;
- Expressividade: sufixos podem externalizar a impressão do falante a respeito de algo ou alguém. A prefixação quase nunca é utilizada para essa finalidade;
- Truncamento: Prefixos podem se comportar como formas livres quando utilizado o processo de truncamento, carregando o significado da base;
- Sufixos são mais densos semanticamente, ou seja, tendem a alterar o significado da base;

Flexão e Derivação

Novas formas podem ser criadas por diferentes processos, mas nem todos os processos criam novos lexemas, ou seja, nem sempre adicionam novas palavras ao léxico. Neste sentido, é possível diferenciar esses processos em flexão e derivação. A flexão resume-se à conjugação dos léxicos, criando novas formas do mesmo item lexical, enquanto a derivação é um processo de formação de novos léxicos.

Na flexão, os morfemas representam conjugações da palavra base (plural, pessoa ou tempo verbal) e, por isso, não adicionam novas palavras ao léxico. No Português, morfemas de flexão normalmente acontecem no final das palavras (sufixos) sem alterar a classe gramatical. Desta forma, as novas palavras representam diferentes realizações do mesmo léxico, mantendo o significado semântico. Além disso, morfemas de flexão tendem a ser mais produtivos e possuem menos regras para serem afixados em uma base. Ou seja, são mais fáceis de serem utilizados.

A derivação de palavras forma novas entradas no léxico, que possuem novos significados semânticos, podendo ocorrer por meio de prefixos e sufixos. Enquanto os sufixos tendem a alterar a classe gramatical, os prefixos derivacionais tendem a mantê-la. Os morfemas de derivação possuem regras mais complexas de uso e, por isso, são menos produtivos que os morfemas de flexão. Isso significa que nem sempre é possível combinar bases com morfemas de derivação.

3.1.2 Léxico Mental

O léxico mental de cada indivíduo é diferente, e nem todas as palavras conhecidas por um falante são conhecidas por outro. Palavras mais frequentes são mais conhecidas e recuperadas com maior agilidade de nosso léxico mental. Desta forma, é possível entender que o conhecimento sobre uma palavra possui um degradê (ou espectro) entre conhecer uma palavra ou não, dado que conhecemos e compreendemos algumas palavras mais do que outras. Na psicolinguística, modelos de processamento morfológico tentam explicar como o significado das palavras é construído a partir dos elementos presentes em nosso léxico mental (Leminen *et al.*, 2019). Esses modelos consideram dois mecanismos de processamento de palavras: rota de decomposição (*computation route* ou *decomposition route*) e a rota de armazenamento (*storage route* ou *whole-word route*) (Hofmann *et al.*, 2021; Plag, 2018). Na rota de armazenamento, as palavras são armazenadas como uma única unidade no léxico mental, enquanto que a rota de decomposição constrói o significado a partir do significado de suas partes.

Palavras complexas idiossincráticas, que não seguem uma regra geral, devem ser armazenadas no léxico mental, pois estas não podem ser construídas a partir de regras. Neste sentido, é possível construir um modelo do léxico mental que contenha apenas casos não previsíveis, ou seja, que considere apenas palavras simples, raízes, afixos e as palavras complexas irregulares, que não podem ser formadas por regras. Neste modelo enxuto, as palavras complexas regulares podem ser construídas a partir das regras. Porém, evidências psicolinguísticas mostram que o léxico mental não funciona dessa forma (Leminen *et al.*, 2019) e que palavras simples e complexas, independentemente de serem regulares ou não, podem ser listadas em nosso léxico mental (Plag, 2018). Em um modelo enxuto não existiria redundância de informações armazenadas, resultando em economia de armazenamento: se uma palavra pode ser gerada a partir de uma regra, não é necessário armazená-la no léxico mental. Porém, o cérebro é otimizado levando em consideração outros aspectos e, para que o processamento seja mais eficiente, em alguns casos, é necessário aumentar esse custo de armazenamento.

Quando há um conflito entre as necessidades de velocidade de processamento e custo de armazenamento, o cérebro favorece a velocidade de processamento. Leminen *et al.* (2019) mostram que existem evidências de que ambos os mecanismos são utilizados para obter uma maior funcionalidade. Assim, a frequência de uma palavra tem fundamental importância para decidir qual dos mecanismos será utilizado. Para explicar como a frequência de uma palavra interfere no mecanismo de processamento, é necessário entender o conceito de *resting activation*, que pode ser entendido como o tempo necessário para "esquecer" uma palavra. Quando uma palavra é utilizada com frequência, o intervalo de uso nunca excede esse tempo e sua ativação nunca chega a zero. Mesmo que palavras complexas possam

ser construídas a partir de seus componentes, a rota de armazenamento é favorecida por ser mais rápida e eficiente. Além disso, quanto maior for a frequência de ativação de uma palavra, menor é o tempo de repouso, tornando palavra cada vez mais consolidada na memória e mais difícil de ser esquecida (Plag, 2018).

De forma resumida, ao considerar os modelos de processamento morfológico, o significado de uma palavra pode ser construído de duas formas: (i) pela rota de armazenamento ou (ii) pela rota de decomposição. Conforme Hofmann *et al.* (2021) apresentam, de forma análoga, é possível relacionar esses dois mecanismos com a forma como os modelos de linguagem (LLMs) baseados em sub-palavras segmentam e processam as palavras de um texto, mesmo que, ao decompor uma palavra, as partes não representem morfemas.

3.2 Modelos de Segmentação (*tokenizers*)

Um dos principais problemas relacionados à segmentação de textos é a construção de um vocabulário que identifique quais segmentos (*tokens*) são reconhecidos por um modelo de linguagem natural. Desta forma, além de preparar e padronizar um texto, o processo de segmentação (*tokenization*) afeta diretamente a forma como esses modelos entendem a língua natural. Diferentes métodos de segmentação podem ser utilizados para a criação de um vocabulário e podem variar entre os níveis de palavras, sub-palavras ou caracteres.

Mesmo que a definição do que é uma palavra mude de aplicação para aplicação (Jurafsky e Martin, 2024), a segmentação em nível de palavras pode apresentar alguns desafios para línguas como o Chinês e o Japonês, onde não há uma separação clara entre palavras, como a presença de espaços em branco. Os principais problemas relacionados a essa abordagem são a necessidade de um vocabulário muito extenso e a presença considerável de palavras desconhecidas. As abordagens em nível de sub-palavras e caracteres aliviam esses problemas e, mesmo com o uso de um vocabulário pequeno e de tamanho fixo, permitem a construção de um vocabulário aberto pela combinação e concatenação dos elementos presentes no vocabulário (sub-palavras e caracteres).

Embora os algoritmos em nível de caracteres permitam a construção de um vocabulário compacto, acabam transformando o texto de entrada em uma sequência muito grande de segmentos, dificultando o treinamento de novos modelos. Ao permitir que caracteres e palavras também sejam incluídos, algoritmos em nível de sub-palavras apresentam um bom equilíbrio entre os dois outros níveis, combinando a flexibilidade de um vocabulário aberto com a representação do texto em uma sequência não muito extensa de segmentos. Por conta dessas características, os algoritmos de segmentação em nível de sub-palavras mostraram-se opções mais adequadas para o treinamento de grandes modelos de linguagem.

A seguir, são apresentados os principais algoritmos de segmentação de textos em nível de sub-palavras, utilizados pela maioria dos grandes modelos de linguagem no estado-da-arte: *Byte-Pair Encoding* (BPE) (Sennrich *et al.*, 2016), *WordPiece* (Schuster e Nakajima, 2012) e *Unigram* (Kudo, 2018). Embora o *SentencePiece* (Kudo e Richardson, 2018) possa ser considerado um método de segmentação por alguns trabalhos na literatura, trata-se de uma ferramenta que implementa os modelos *Unigram* e BPE. Porém, além da ferramenta, Kudo e Richardson (2018) também apresentam uma forma específica de pré-processamento, que justifica sua menção na literatura como um método de segmentação. Como o foco

deste trabalho está na comparação dos modelos de segmentação, o *SentencePiece* não será considerado como um método de segmentação, mas uma ferramenta.

3.2.1 *WordPiece*

O *WordPiece* (Schuster e Nakajima, 2012) foi desenvolvido para a construção de um sistema de busca do Google para o Japonês e o Coreano, buscando superar os desafios técnicos presentes nas línguas asiáticas, que normalmente não eram considerados pelas técnicas utilizadas para línguas como o Inglês. Um dos principais desafios técnicos presentes em línguas asiáticas é o inventário básico de símbolos muito grande, misturando vários alfabetos no mesmo texto, com poucos casos de palavras separadas por espaços em branco. Neste contexto, o *WordPiece* surge como uma solução baseada em dados que pode ser aplicada à diferentes línguas sem a necessidade de modificações.

Partindo dos menores segmentos possíveis (caracteres e símbolos), o algoritmo produz um número máximo de segmentos de forma gulosa ao maximizar a verossimilhança de um modelo de linguagem. Schuster e Nakajima (2012) descrevem o algoritmo, para o Japonês e o Coreano, da seguinte forma:

1. O inventário de segmentos é inicializado com os caracteres Unicode básicos, incluindo os caracteres ASCII. Esse conjunto básico foi definido de forma diferente para cada língua, resultando em 22000 caracteres para o Japonês e 11000 caracteres para o C+oreano;

2. Construir um modelo de linguagem com os dados de treinamento utilizando o inventário obtido no passo 1 (n-grama);

3. Gerar uma nova unidade de palavra a partir da combinação de duas unidades presentes no inventário para incrementar o tamanho em um. O novo segmento é escolhido de forma a maximizar a verossimilhança dos dados de treinamento;

4. Repetir o processo a partir do passo 2 até que o limite de segmento seja atingido ou a verossimilhança seja menor que um limiar.

Esse algoritmo pode ser custoso caso sejam consideradas todas as possibilidades de combinação, mas pode ser mais eficiente ao:

- testar apenas as combinações existentes nos dados;
- testar pares com alta probabilidade de ocorrência (probabilidade à priori alta);
- combinar grupos de segmentos que não influenciam a ocorrência de outros segmentos em um único passo;
- modificar a contagem do modelo de linguagem somente para as entradas afetadas.

Embora os autores apresentem o método *WordPiece* como uma forma de evitar a produção de segmentos desconhecidos (OOVs), dependendo do inventário de caracteres iniciais utilizados, se o texto a ser processado apresentar algum símbolo que não esteja nesse inventário básico, como um emoji, por exemplo, resultará em um segmento desconhecido.

Este método de segmentação foi utilizado pelo BERT (Devlin *et al.*, 2018), mas sua implementação nunca foi disponibilizada de forma aberta pelo Google. Algumas bibliotecas fornecem o *WordPiece* como método de segmentação, mas são aproximações baseadas em premissas. A biblioteca *tokenizers*,[1] por exemplo, utiliza a seguinte fórmula para calcular um *score* para selecionar os pares que irão gerar novas entradas no inventário de segmentos:

$$score = \frac{freq_{par}}{freq_a \times freq_b} \tag{3.1}$$

em que $freq_{par}$ representa a frequência absoluta de ocorrência de um par de segmentos (a, b), $freq_a$ representa a frequência absoluta do primeiro segmento e $freq_b$ representa a frequência absoluta do segundo segmento.

3.2.2 *Byte Pair Enconding*

O método de segmentação *Byte Pair Encoding* surge no contexto das traduções automáticas (*machine translation*), um problema de vocabulário aberto que era tratado, até então, pelo uso de redes neurais artificiais com segmentação em nível de palavras em combinação com um dicionário para tratar da tradução de palavras desconhecidas. Para resolver essa limitação imposta pela segmentação em nível de palavras e reduzir consideravelmente a quantidade de palavras desconhecidas, Sennrich *et al.* (2016) se basearam no algoritmo de compressão de dados de mesmo nome (*Byte Pair Encoding*), possibilitando utilizar apenas a rede neural artificial e obter bons resultados na tarefa de tradução automática.

Enquanto o algoritmo de compressão de dados substitui, de forma iterativa, os pares de *bytes* mais frequentes por um único *byte* que não foi utilizado, Sennrich *et al.* (2016) perceberam que era possível modificá-lo e unir o par para gerar uma nova entrada no vocabulário do modelo, assim como é feito pelo *WordPiece*. Desta forma, o algoritmo inicia com um vocabulário base que contém todos os caracteres e expande o vocabulário ao incluir os pares mais frequentes. Esse processo iterativo repete-se até que o tamanho máximo do vocabulário seja atingido, sendo este o único hiper-parâmetro do algoritmo. O vocabulário inicial define as unidades mais básicas de sub-palavras e qualquer símbolo que não esteja neste conjunto resultará em segmentos desconhecidos (OOVs). Por ser baseado em um algoritmo de compressão de dados, o *Byte Pair Encoding* acabou adquirindo algumas características interessantes para o treinamento de grandes modelos de linguagem, criando sequências compactas de segmentos. Embora o algoritmo e a estratégia de treinamento do BPE seja idêntica ao *WordPiece*, eles se diferenciam pela forma como os pares de segmentos são escolhidos para expandir o vocabulário corrente.

Normalmente, o BPE é utilizado para processar caracteres Unicode e, para evitar a possibilidade de palavras desconhecidas, seria necessário utilizar um vocabulário inicial com mais de 130.000 caracteres, antes mesmo de incluir qualquer segmento multi-caracteres. Por conta da natureza dos modelos de redes neurais artificiais, utilizar um vocabulário dessa magnitude mostrou-se impraticável, resultando em um conjunto muito maior do que os tamanhos adotados pelos modelos até então. Ao utilizarem uma versão do BPE

[1] Detalhes de implementação do *WordPiece* estão disponíveis em: https://huggingface.co/learn/llm-course/chapter6/6

em nível de *bytes*, Radford, Wu *et al.* (2019) permitiram que o vocabulário inicial do GPT-2 ficasse contido em um conjunto de 256 *bytes*, eliminando qualquer possibilidade do algoritmo produzir palavras desconhecidas.

3.2.3 *Unigram*

Ao construir um vocabulário de sub-palavras, é possível criar diferentes segmentações para o mesmo texto, utilizando diferentes combinações de sub-palavras. Essa diferença possibilita a criação de representações ambíguas, que podem ser entendidas como entradas completamente diferentes pelo modelo. Ao perceber isso, Kudo (2018) propõe um novo método de regularização para treinar modelos de tradução automática. O método de regularização de sub-palavras procura introduzir ruídos nos dados de entrada para permitir que o modelo aprenda uma representação mais robusta à esses ruídos e possibilite ao modelo aprender representações de composicionalidade de palavras e entender que a palavra "*livros*" pode ser decomposta em "*livro*" + "*s*".

Para que o processo de regularização possa ser aplicado, é necessário utilizar um algoritmo que permita o uso de diferentes segmentações. Embora a natureza determinística do BPE garanta que um texto sempre seja decomposto na mesma sequência de segmentos, isso o torna limitado para o uso na regularização de sub-palavras. Para contornar esse problema, Kudo (2018) apresenta um novo método de segmentação baseado no modelo de linguagem Unigram, nomeando este novo método. A introdução de um modelo de linguagem ao processo de segmentação de texto permitiu o cálculo de probabilidades para diferentes segmentações e a amostragem, com base nessas probabilidades, para utilização de diferentes segmentações durante o treinamento do modelo de tradução automática.

Diferente dos métodos *WordPiece* e *Byte Pair Encoding*, que constroem o vocabulário partindo das unidades mais básicas e incrementando seu tamanho a partir da concatenação desses componentes, o *Unigram* parte de um vocabulário muito grande, eliminando de forma iterativa os elementos menos importantes até chegar ao tamanho desejado. Desta forma, o algoritmo de treinamento do *Unigram* é descrito da seguinte forma:

1. Inicializar o vocabulário de forma heurística utilizando o corpus de treinamento;
2. Repetir os seguintes passos até que o vocabulário atinja o tamanho desejado:
   (a) Com o vocabulário definido, calcular as probabilidades $p(x_i)$ para cada segmento x_i;
   (b) Calcular a $loss_i$, que representa quanto de perda é introduzida quando o segmento x_i é removido do vocabulário. Desta forma, é possível identificar os segmentos que possuem menor impacto e removê-los do vocabulário, minimizando o impacto na $loss$ do modelo;
   (c) Ordenar os segmentos e remover os $n\%$ com menor valor de $loss_i$. Para evitar o aparecimento de OOVs, é necessário manter os caracteres básicos;

Para inicializar o vocabulário para o *Unigram* é possível criar um conjunto com os caracteres básicos e os segmentos (sub-palavras) mais frequentes. O algoritmo *Enhanced Suffix Array* se mostra uma boa opção para encontrar os segmentos mais frequentes. Dentre

um conjunto de segmentações possíveis $S(X)$, a segmentação mais provável x^* pode ser obtida com o algoritmo Viterbi.

3.3 Arquitetura *Transformers*

Transformers é uma arquitetura de rede neural artificial desenvolvida para o tratamento de problemas *sequence-to-sequence* que segue o modelo *encoder-decoder* (Vaswani *et al.*, 2017). Sua principal inovação foi a introdução de um mecanismo de auto-atenção neural que permitiu criar uma relação entre todos os *tokens* de uma sequência, capturando relações de longa distância enquanto eliminava as complexidades apresentadas pelas arquiteturas recorrentes utilizadas até então. O mecanismo de auto-atenção possibilitou o processamento paralelo dos *tokens*, permitindo escalar o modelo de forma mais eficiente e reduzir consideravelmente o tempo de treinamento em grandes bases de dados, tornando-se a arquitetura padrão para a construção de modelos de linguagem no estado-da-arte, incorporada em modelos como BERT (Devlin *et al.*, 2018), GPT (Radford, Wu *et al.*, 2019) e Qwen (Yang *et al.*, 2025).

A arquitetura *Transformers* é composta por várias camadas, divididas em *encoder* e *decoder*. Cada bloco do *encoder* contém um componente de atenção neural (*multi-head attention*) e uma rede *feed-forward*, além de conexões residuais e camadas de normalização.

3.3.1 Qwen

Qwen é uma família de modelos de linguagem, sendo o Qwen3 (Yang *et al.*, 2025) a versão mais recente disponível durante o desenvolvimento deste trabalho. Baseado apenas no *decoder* da arquitetura *Transformer*, o Qwen3 traz melhorias em eficiência e estabilidade. O modelo utiliza RoPE (*Rotary Positional Embeddings*), que permite trabalhar com sequências mais longas de contexto sem degradar a qualidade do mecanismo de atenção. O modelo também utiliza uma nova forma de normalização (RMSNorm), múltiplas cabeças de atenção com kernel de atenção otimizado e camadas *feed-forward* mais profundas que aumentam a qualidade de representação, mantendo a eficiência computacional.

O modelo Qwen3 utiliza segmentação BPE em nível de bytes para criar representações multilinguísticas, aumentando consideravelmente a quantidade de línguas suportadas em relação à sua versão anterior. Para o seu pré-treinamento, foram utilizadas três etapas:

1. Estágio Geral: utilizou sequências de 2048 *tokens* em uma base com cerca de 30 trilhões de *tokens*, permitindo ao modelo aprender conhecimentos gerais sobre o mundo;
2. Estágio de Raciocínio: neste estágio, o treinamento do modelo focou em bases com conhecimentos mais técnicos para aumentar a capacidade de raciocínio do modelo;
3. Estágio de Longos Contextos: nesta etapa, a sequência de entrada aumentou para tamanhos entre 2^{14} e 2^{15} *tokens*, permitindo ao modelo processar contextos cada vez maiores.

Capítulo 4

Métodos

Neste capítulo, são apresentados os métodos utilizados para avaliar a hipótese de que a presença de segmentos morfológicos exerce influência na capacidade de generalização de LLMs para o Português. Inicialmente, na Seção 4.1, é apresentado o método MorphEval-PT, proposto para a avaliação da presença de segmentos dotados de semântica, baseado nos modelos psicolinguísticos de processamento morfológico. A Seção 4.2.1 apresenta o Corpus Carolina, utilizado para o pré-treinamento dos modelos de linguagem Qwen-PT. Na Seção 4.3, são apresentadas as diferentes tarefas utilizadas para avaliar a performance dos modelos Qwen-PT.

4.1 MorphEval-PT: Avaliando segmentos morfologicamente coerentes

Para avaliar a presença de segmentos morfologicamente coerentes na segmentação produzida por diferentes modelos de segmentação, foi necessário construir uma base de dados. Para isso, foram utilizados os dados disponíveis na MorphyNet (Batsuren *et al.*, 2021). A base de dados original e todo o seu processo de tratamento são descritos a seguir.

4.1.1 MorphyNet

MorphyNet[1] é uma base de dados multilíngue que contém informações sobre análise morfológica, incluindo morfemas relacionados aos processo de formação de palavras por derivação e flexão (Batsuren *et al.*, 2021). Sua construção foi dividida em duas etapas: extração e enriquecimento. A extração dos dados foi realizada a partir das informações contidas no Wikcionário,[2] que possui informações linguísticas de diversas línguas, incluindo o Português. Em seguida, na etapa de enriquecimento dos dados, foram aplicadas regras de inferência para gerar novas entradas para a MorphyNet.

[1] Disponível em: https://github.com/kbatsuren/MorphyNet

[2] Em inglês, *Wiktionary*. Disponível em: https://www.wiktionary.org/

Outros trabalhos já haviam explorado o Wikcionário para a construção de bases morfológicas (Kirov *et al.*, 2018; Metheniti e Neumann, 2020), porém, Batsuren *et al.* (2021) criaram novas regras de extração a partir da observação de padrões recorrentes, permitindo a obtenção de um conjunto de dados maior e com mais informações. Para expandir ainda mais a base de dados, na etapa de enriquecimento, foram utilizadas algumas regras para gerar novas entradas. Considerando que o processo de construção da base de dados foi dividido de acordo com os processos de formação de palavras (derivação e flexão), diferentes regras de expansão foram utilizadas para cada caso.

Para enriquecer os dados relativos à derivação, os autores utilizaram a CogNet (Batsuren *et al.*, 2022), uma base de cognatos[3] que permitiu inferir a aplicabilidade de afixos para gerar novas entradas para a MorphyNet, resultando em um aumento de 26% nos casos de derivação. Para a ampliação da base relativa aos processos de flexão, também foram criadas regras de inferência para incluir casos faltantes, identificados pelos autores, aumentando em 10,8% o tamanho da MorphyNet. Como resultado final, a base de dados disponibilizada para o Português contém 388115 entradas, sendo 376341 registros de flexão e 11774 registros de derivação (ver Tabela 4.1).

	Formas	Palavras	Morfemas
Flexão	376341	39029	158
Derivação	11774	6076	387
Total	388,115		

Tabela 4.1: *MorphyNet: Tamanho da base disponibilizada para o Português em cada processo de formação de palavras. Formas representa o total de entradas. Palavras é o número de palavras únicas, utilizadas como base do processo de formação de palavras. Morfemas é o número de morfemas diferentes utilizados para transformar a palavra base.*

Os dados de flexão e derivação da MorphyNet estão separados em arquivos distintos, contendo formatos e informações diferentes. Para a morfologia de flexão, exemplificada na Tabela 4.2, estão disponíveis informações sobre o lema, forma flexionada, análise morfológica e segmentação em morfemas. Os rótulos da análise morfológica estão alinhados com a segmentação de morfemas, de modo que cada rótulo e morfema estão separados pelo símbolo "|". No caso da segmentação de morfemas, ela representa uma segmentação em nível mais profundo, contendo a raiz da palavra e seus morfemas, impossibilitando que a concatenação dos elementos resulte na forma flexionada.

Os dados de derivação seguem um padrão semelhante, exemplificados na tabela 4.3, incluindo informações sobre a palavra de origem, sua forma derivada, as classes gramaticais (POS, do inglês *Part of Speech*), o afixo utilizado para gerar a forma derivada e o tipo deste afixo (prefixo ou sufixo). Novamente, a concatenação entre a palavra de origem e o afixo não gera a palavra derivada. Por conta dessas características, os dados disponibilizados na base da MorphyNet apresentam algumas limitações em seu uso para a segmentação em nível superficial.

[3] Cognatos são palavras de línguas diferentes, mas que possuem a mesma origem e, por isso, seus significados e grafias também são semelhantes. As palavras *imagine* (inglês) e *imaginar* (português) são exemplos de cognatos.

Lema	Forma Flexionada	Análise Morfológica	Morfemas
infiltrar	infiltrar	V;NFIN	-
infiltrar	infiltrar	V;1;SG;NFIN	-
infiltrar	infiltrares	V;NFIN|2;SG	infiltrar|ares
infiltrar	infiltrarmos	V;NFIN|1;PL	infiltrar|armos
infiltrar	infiltrardes	V;NFIN|2;PL	infiltrar|ardes
infiltrar	infiltrarem	V;NFIN|3;PL	infiltrar|arem
infiltrar	infiltrado	V|V.PTCP;PST;MASC;SG	infiltrar|ado
infiltrar	infiltrados	V|V.PTCP;PST|MASC;PL	infiltrar|ado|s
infiltrar	infiltrada	V|V.PTCP;PST|FEM;SG	infiltrar|ado|a
infiltrar	infiltradas	V|V.PTCP;PST|FEM|PL	infiltrar|ado|a|s

Tabela 4.2: *Exemplo de flexões presentes na MorphyNet.*

Origem	Derivação	POS Origem	POS Derivação	Afixo	Tipo
moral	amoral	J	J	a	prefix
cento	centavo	N	N	avo	suffix
adição	adicionar	N	V	ar	suffix
música	musical	N	J	al	suffix
jurar	juramento	V	N	mento	suffix
cultural	multicultural	J	J	multi	prefix
Itália	italiano	N	J	ano	suffix
labial	bilabial	J	J	bi	prefix
haver	reaver	V	V	re	prefix
logia	psicologia	N	N	psico	prefix

Tabela 4.3: *Exemplo de Derivações presentes na MorphyNet.*

Qualidade dos dados

Batsuren *et al.* (2021) indicam uma excelente qualidade dos dados presentes na MorphyNet, resultando em uma precisão acima de 98% ao considerar uma avaliação manual realizada por especialistas. Porém, essa avaliação considerou apenas uma amostra de algumas das línguas presentes na MorphyNet, sem incluir o Português nesse conjunto.

Os dados de flexão e derivação da MorphyNet também foram avaliados por meio da comparação com uma base de referência (*ground truth*). Em relação aos dados de flexão, foram avaliadas as informações sobre os rótulos da análise morfológica e classes gramaticais, comparando-os com os dados do *treebank Universal Dependencies* (Nivre *et al.*, 2020). Mais uma vez, os dados disponibilizados pela MorphyNet para o Português não foram avaliados.

Para os dados de derivação, os autores consideraram como referência o UDer (*Universal Derivations*) (Kyjánek *et al.*, 2020), uma base de dados que agrupou diversos recursos monolinguísticos disponibilizado-os com o mesmo formato. Nesta base, os dados em Português foram extraídos do NomLex-PT (Paiva *et al.*, 2014), uma base de nominalizações que inclui informações sobre as classes gramaticais de suas entradas. Ao realizar a avaliação dos dados de derivação em Português, Batsuren *et al.* (2021) utilizaram a intersecção entre

MorphyNet e UDer, resultando em um conjunto de apenas 1.235 entradas, representando pouco mais de 1/3 dos dados em Português do UDer.

Mesmo que Batsuren *et al.* (2021) não apresentem uma análise adequada e completa sobre a qualidade dos dados em Português, consideramos que a análise e os resultados apresentados em outras línguas é suficiente para caracterizar o processo de construção da MorphyNet como robusto e que as informações presentes no Wikcionário possuem um bom grau de qualidade. Portanto, mesmo que não seja possível concluir algo sobre a qualidade dos dados em Português, ainda assim, pela robustez do processo, a MorphyNet será considerada como fonte para os próximos passos do desenvolvimento desta pesquisa.

4.1.2 Filtragem e Transformação

Para garantir uma maior qualidade dos dados presentes na MorphyNet, foi realizada uma análise preliminar para garantir que as palavras estejam, de fato, presentes no vocabulário do Português Brasileiro. Para isso, todas as palavras foram verificadas com base no corretor ortográfico *Enchant/Hunspell*,[4,5] que utiliza o dicionário do Português Brasileiro desenvolvido pelo Projeto VERO.[6] Nesta primeira etapa, foram mantidos todos os registros em que ao menos o lema/origem ou a forma flexionada/derivada foram validadas pelo verificador ortográfico. Dentre as palavras rejeitadas pelo dicionário foram encontradas palavras arcaicas, em inglês, pertencentes ao Português Europeu ou com erros ortográficos. Exemplos de palavras removidas são apresentadas na Tabela 4.4. Embora alguns casos pudessem ser considerados válidos, como o neologismo *wikificar*, apenas as palavras validadas pelo corretor ortográfico foram mantidas nessa etapa de filtragem.

Lema/Origem	Flexão/Derivação	Filtro
atómico	**di**atómico	Português Europeu
económico	**agro**económico	Português Europeu
prémio	prémio**s**	Português Europeu
pré-cozer	pré-coz**ermos**	Português Europeu
comprehender	comprehend**erem**	Português Arcaico
cometter	comett**erem**	Português Arcaico
aliasing	**anti-**aliasing	Inglês
wiki	wik**ificar**	Inválida

Tabela 4.4: *Exemplo de palavras filtradas pelo corretor ortográfico. As formas flexionadas e derivadas apresentam seus afixos em negrito.*

Alguns casos presentes nos dados de flexão não incluem a segmentação em afixos, conforme exemplo presente na Tabela 4.2. Em casos assim, a flexão não ocorre pela adição de afixos que causam alterações ortográficas, mas pela alteração na estrutura morfológica. Para melhor exemplificar esse caso, considere a palavra *infiltrar*[7] que pode representar tanto

[4] https://rrthomas.github.io/enchant/

[5] https://github.com/hunspell/hunspell

[6] https://pt-br.libreoffice.org/projetos/vero

[7] https://pt.wiktionary.org/wiki/infiltrar

o lema no infinitivo impessoal como as formas flexionadas n o infinitivo pessoal na primeira ou na terceira pessoa. Embora a estrutura morfológica da forma flexionada seja diferente da estrutura do lema, a ortografia é a mesma e, por conta disso, a MorphyNet não disponibiliza uma segmentação de morfemas para esses casos. Como o objetivo deste trabalho busca avaliar a presença de afixos na segmentação de modelos de linguagem, e a informação sobre a análise morfológica é descartada, estes casos também foram desconsiderados durante a construção dos dados de avaliação.

Como é possível observar na Tabela 4.3, os dados de derivação não permitem uma construção direta de uma sequência de morfemas que, ao serem concatenados, resulte na palavra derivada. O mesmo problema surge com os dados de flexão (ver tabela 4.2), onde a segmentação dos morfemas também segue uma representação profunda, na qual os morfemas são apresentados em sua forma canônica. Para que o objetivo deste trabalho seja alcançado, é necessário que a segmentação de morfemas seja representada de forma superficial, permitindo que a sequência de morfemas, ao serem concatenados, reconstruam a palavra flexionada, assim como acontece com os segmentadores (*tokenizers*) dos modelos de linguagem a serem avaliados.

Para obter a segmentação de morfemas em nível superficial,[8] cada processo de formação de palavra foi transformado seguindo regras próprias, de acordo com o formato dos dados. Ao considerar os morfemas nos dados de flexão, o primeiro segmento foi desconsiderado por representar o lema. Além disso, foi necessário alterar a forma de alguns morfemas femininos, como `ado|a`, que foi alterada para a sua forma superficial `ada`. Com base nos sufixos corrigidos, foi possível removê-los da forma flexionada e obter uma segmentação de morfemas em nível superficial, onde a concatenação dos morfemas resulta na palavra flexionada. Como exemplo, a palavra *infiltradas*, que possui a representação profunda `infiltrar|ado|a|s`, foi convertida para `infiltr|ada|s`. Embora a conversão tenha sido possível, para garantir que a concatenação dos morfemas na representação superficial resulte na palavra flexionada, foi realizada uma última etapa de validação e casos que não cumpriram esse requisito foram removidos da base final.

A conversão dos casos de derivação foi mais simples e direta, sendo necessário apenas remover o afixo da palavra derivada com base em seu tipo (prefixo ou sufixo), resultando em uma segmentação de 2 morfemas, aqui considerados como base e afixo. Como exemplo, considere a palavra *moral* e sua forma derivada *amoral* (ver Tabela 4.3). Ao separar o prefixo *a-* da forma derivada, foi possível obter a sequência de morfemas `a|moral`. No caso de sufixos, a obtenção dos morfemas aconteceu pela separação ao final da palavra. A forma derivada *adicionar* resultou, então, na sequência `adicion|ar` ao considerar o sufixo *-ar*. A validação da reconstrução da palavra derivada também foi realizada, e palavras que não cumpriram esse critério foram excluídas da base final.

Os dados referentes aos números de registros filtrados em cada etapa, juntamente com o tamanho final da base de dados construída, são apresentados na Tabela 4.5. Embora alguns casos pudessem ser avaliados manualmente e incluídos na base final, esse processo não foi realizado por se tratar de um processo manual, extenso e que requer conhecimento especializado. Portanto, casos válidos e que poderiam ser incluídos foram desconsiderados

[8] O script desenvolvido para converter a segmentação profunda em superficial está disponível em: https://github.com/guilhermelmello/MorphEval-PT

para simplificar as regras de filtragem e construção da base de avaliação.

Filtros	Derivação	Flexão
Sem Morfemas	0	58847
Palavras Inválidas	243	17687
Morfemas Inválidos	30	0
MorphyNet	11774	376341
Filtrados	273 (2.32%)	76534 (20.34%)
Base final	11501 (97.68%)	299807 (79.66%)

Tabela 4.5: *Informações sobre a construção da base de avaliação e quantas entradas foram removidas em cada filtro. "Sem Morfemas" representa as entradas que não disponibilizam uma segmentação de morfemas, "Palavras Inválidas" correspondem às palavras não identificadas pelo corretor ortográfico e "Morfemas Inválidos" representam entradas em que a sequência de morfemas não permite a reconstrução da forma flexionada/derivada.*

O formato final da base de dados seguiu o mesmo formato original, presente na MorphyNet, separando os dados de flexão e derivação em arquivos `.tsv` distintos, porém, foram mantidas apenas as informações relevantes para os experimentos futuros. Em ambos os casos, a primeira coluna representa a palavra em sua forma derivada ou flexionada, que será utilizada como entrada para avaliar os segmentadores dos modelos de linguagem. A segunda coluna é formada pela sequência de morfemas, em sua forma superficial, separados pelo símbolo "|". Enquanto os dados de flexão possuem apenas essas duas colunas, uma terceira coluna está presente na base de derivação, informando qual o tipo de afixo está presente na sequência de morfemas (prefixo ou sufixo). Todas as demais informações, originalmente presentes na MorphyNet, foram descartadas.

4.1.3 Limitações

Após o processo de filtragem e construção da base de dados final, foram obtidos 388 afixos de derivação (188 prefixos e 200 sufixos) e 162 sufixos de flexão. Porém, como é possível ver na Tabela 4.6, alguns afixos acabaram se mostrando muito mais frequentes que outros, como é o caso dos afixos de derivação *anti-* e *-mente* e do afixo de flexão *-s*. Embora os sufixos *-mente* e *-s* sejam comuns e recorrentes na língua portuguesa, a frequência com que ocorrem na base pode induzir, de algum modo, na avaliação, e favorecer segmentadores que sejam bons na identificação desses afixos. Mesmo assim, nenhum tratamento extra foi realizado para ajustar a distribuição dos afixos.

Os dados apresentados na Tabela 4.6 podem diferir dos dados apresentados na base da MorphyNet por se tratar de análises morfológicas em níveis diferentes. Enquanto a base da MorphyNet faz a segmentação em nível profundo, recuperando os morfemas em suas formas profundas, neste trabalho, foi construída uma segmentação em nível superficial. Portanto, casos de alomorfia, que são representados como um único morfema pela MorphyNet, são representados por diferentes morfes na base gerada por este trabalho.

Outro problema que traz uma limitação ao uso da base construída está na segmentação, originalmente disponibilizada pela MorphiNet. Como a base de flexão trata apenas dos sufixos de flexão, entradas que contenham prefixos de derivação não constam como mor-

Derivação				Flexão	
Prefixos (188)		Sufixos (200)		Sufixos (162)	
1073	*anti-*	1415	*-mente*	26881	*-s*
266	*des-*	807	*-ar*	11857	*-e*
176	*a-*	662	*-ção*	10745	*-a*
158	*re-*	392	*-ico*	8508	*-amos*
158	*in-*	332	*-mento*	7853	*-emos*
61	*auto-*	292	*-idade*	7825	*-em*
37	*bio-*	258	*-ismo*	7198	*-ada*
36	*sub-*	256	*-dor*	7198	*-aria*
32	*agro-*	224	*-eiro*	7196	*-ado*
32	*mono-*	218	*-ista*	7176	*-ava*

Tabela 4.6: *Ao todo, foram obtidos 388 afixos de derivação (188 prefixos e 200 sufixos) e 162 sufixos de flexão. São apresentados os 10 afixos mais frequentes, nos dados gerados, para cada caso, juntamente com com suas frequências absolutas.*

femas segmentados, sendo mantidos juntamente da base da palavra complexa, conforme exemplificado a seguir:

- *anticonsumistas* - **anti**`consumista|s`
- *desempates* - **des**`empate|s`
- *ilegalidades* - **i**`legalidade|s`
- *prefabricados* - **pre**`fabric|ado|s`

Algo semelhante também ocorre com os dados de derivação, em que os afixos são avaliados em diferentes entradas da base, como é o caso de *antimoralismo*, segmentado como `anti|moralismo`. Embora a base *moralismo* não seja segmentada com o sufixo *-ismo*, existe uma outra entrada da base que trata deste caso, onde a palavra *moralismo* é segmentada como `moral|ismo`. O mesmo acontece para outras palavras, como *amoralismo*, *descolonização* e *autobiográfico*, exemplificadas na Tabela 4.7. Outro exemplo é a palavra *descolonização*, que possui duas entradas na base de dados com as segmentações `des|colonização` e `descoloniza|ção`. Porém, ao considerar a base *colonização*, que também possui uma entrada segmentada como `coloniza|ção`, é possível caracterizar um caso de redundância na avaliação do sufixo *-ção*.

Embora a segmentação completa de uma palavra complexa possa ser avaliada ao unificar diferentes entradas, seria necessário avaliar a extensão dessa característica, já que não existem garantias de que todas as palavras seguem essa regra. A avaliação desta característica requer conhecimento especializado em morfologia e foge do escopo deste trabalho. Mesmo que esta seja uma característica presente nesses dados, não sabemos qual a sua extensão e confiabilidade e, para garantir uma melhor qualidade e consistência dos resultados apresentados neste trabalho, optamos por uma uma avaliação limitada à segmentação de afixos, em vez de uma segmentação completa de morfemas.

Palavra Derivada	Segmentação
amoralismo	amoral|ismo
amoral	a|moral
antimoralismo	anti|moralismo
moralismo	moral|ismo
anticolonização	anti|colonização
colonização	coloniza|ção
descolonização	des|colonização
descolonização	descoloniza|ção
colonização	coloniza|ção
autobiográfico	auto|biográfico
autobiográfico	autobiográf|ico
biográfico	biográf|ico

Tabela 4.7: *Os casos apresentados na parte superior mostram que é possível identificar afixos não segmentados ao avaliar a segmentação da base da palavra complexa. Os casos exemplificados na parte inferior mostram que alguns casos podem ser redundantes.*

4.1.4 Métricas de Avaliação

Para avaliar os resultados obtidos, serão utilizadas as medidas de *precisão*, *cobertura* e *F1* (Creutz e Linden, 2004). Normalmente, essas medidas são utilizadas para avaliar a qualidade de predição em problemas de classificação binária. Neste contexto, ao comparar a resposta de um modelo de predição com o valor esperado, é possível encontrar diferentes cenários, permitindo a construção do que é chamado de **matriz de confusão**:

- **Verdadeiro Positivo (VP):** número de casos em que o modelo previu como positivo e estava correto;
- **Verdadeiro Negativo (VN):** número de casos em que o modelo previu como falso e estava correto;
- **Falso Positivo (FP):** número de casos em que o modelo previu como positivo mas estava errado;
- **Falso Negativo (FN):** número de casos em que o modelo previu como falso mas estava errado;

Os casos VP e VN representam os dois tipos de acertos de um modelo, enquanto FP e FN representam dois tipos de erros cometidos. Para tratar o problema de segmentação como um problema de classificação binária, é necessário considerar todos os pontos em que é possível segmentar uma palavra como um rótulo distinto (Creutz e Linden, 2004). Portanto, toda separação de caracteres é considerada uma possibilidade de segmentação e uma classificação a ser realizada para indicar se há segmentação ou não. Desta forma, a segmentação de uma palavra é representada por uma sequência de rótulos de classificação.

Por exemplo, a palavra *amoralismo* pode ser segmentada em 9 posições diferentes e, segundo a base de dados, espera-se que ela seja segmentada como `amoral|ismo`, indicada pelos seguintes rótulos $[0, 0, 0, 0, 0, 1, 0, 0, 0]$. Utilizando outro exemplo citado anteriormente, a segmentação `infiltr|ada|s` espera como resposta os rótulos $[0, 0, 0, 0, 0, 0, 1, 0, 0, 1]$.

$$amoral|ismo \rightarrow A_0M_0O_0R_0A_0L_1I_0S_0M_0O \rightarrow [0,0,0,0,0,1,0,0,0] \tag{4.1}$$

$$infiltr|ada|s \rightarrow I_0N_0F_0I_0L_0T_1R_0A_0D_0A_1S \rightarrow [0,0,0,0,0,1,0,0,0,1] \tag{4.2}$$

Os problemas relacionados com a segmentação incompleta e as implicações na avaliação dos resultados serão discutidos nas seções seguintes.

Precisão

Com base na matriz de confusão, a precisão (*precision*) mede a quantidade de acertos (VP) feitos pelo modelo em relação aos casos identificados como positivos ($VP + FP$), ou seja, dos casos identificados pelo modelo como positivos, quantos realmente foram corretos. A precisão pode ser calculada da seguinte forma:

$$Precisão = \frac{VP}{VP + FP} \tag{4.3}$$

No contexto deste trabalho, a precisão mede quantas das segmentações realizadas pelos modelos foram realizadas corretamente, trazendo indícios sobre a qualidade semântica dos segmentos gerados. Assim, uma alta precisão indica que os segmentos gerados normalmente resultam na correta separação de morfemas. Já uma precisão baixa indica que o modelo está separando muito mais do que apenas morfemas, indicando uma baixa qualidade semântica.

Para exemplificar a diferença entre esses dois casos, considere a palavra *infiltradas* como entrada, e que deve ser segmentada como `infiltr|ada|s` ($[0,0,0,0,0,0,1,0,0,1]$). Em um segmentador em nível de caracteres, onde todos os caracteres são separados, todos os rótulos serão positivos: $[1,1,1,1,1,1,1,1,1,1]$. Como resultado, para a palavra *infiltradas*, será obtido apenas 20% de precisão (8 FP e 2 VP). O ideal é esperar que a segmentação aconteça de acordo com a resposta alvo para resultar em 100% de precisão (0 FP e 2 VP). Porém, para que os segmentos gerados contenham conteúdo semântico, a segmentação não necessita ser precisa na quantidade de morfemas identificados, mas as delimitações entre os segmentos devem seguir uma delimitação morfologicamente coerente (Hofmann *et al.*, 2021). Caso o modelo faça apenas uma segmentação em *infiltradas* e esta corresponda à separação entre morfemas ($[0,0,0,0,0,0,1,0,0,0]$ ou $[0,0,0,0,0,0,0,0,0,1]$), ainda temos um cenário interessante. Neste caso, ainda há composição semântica pela correta identificação de segmentos morfológicos, sendo representado por uma precisão de 100% (0 FP e 1 VP).

Um dos motivos pelo qual a composição semântica ainda é interessante mesmo que nem todas as separações entre morfemas sejam identificadas está no entendimento de que os segmentadores dos modelos de linguagem (*tokenizers*) conseguem incorporar mais informação em uma mesma janela de contexto ao produzir uma quantidade menor de segmentos. Modelos de segmentação como o BPE se beneficiam da frequência para unir sub-palavras e a avaliação semântica permite uma boa avaliação deste tipo de modelo.

Considerando o modelo de processamento morfológico, palavras que acontecem de forma frequente em nosso vocabulário tendem a ser processadas de forma mais eficiente

pela rota de armazenamento. Desta forma, casos em que nenhuma segmentação é gerada, ativando a rota de armazenamento, também devem ser tratados como segmentos semanticamente relevantes. Palavras inteiras também colaboram para reduzir o número de segmentos em uma janela de contexto. Assim, casos quando não há segmentação em sub-palavras também resultam em precisão de 100%.

Conforme discutido na seção 4.1.3, as segmentações disponíveis para avaliação não representam segmentações morfológicas completas. Utilizando o exemplo anterior, é possível identificar a ausência da segmentação do prefixo *in-* em `infiltr|ada|s`. Desta forma, modelos que produzam a segmentação deste prefixo resultarão em *falsos positivo*, mesmo que a segmentação esteja morfologicamente correta. Para melhor avaliar a capacidade de composição semântica, ao produzir os rótulos de segmentação, serão consideradas apenas as separações a partir da primeira posição do afixo até a extremidade da palavra. Portanto, ao invés de avaliar *infiltradas* como `infiltr|ada|s`, será considerada apenas como `|ada|s`, resultando nos rótulos $[1, 0, 0, 1]$. Para casos de prefixos, como em `re|aver`, serão produzidos os rótulos $[0, 1]$ para `re|`. Desta forma, qualquer segmentação realizada na base da palavra será desconsiderada. Embora esse tipo de avaliação ignore segmentações em excesso na base da palavra, por conta das limitações dos dados, avaliar apenas os afixos parece ser um caminho mais produtivo na busca por indícios que corroborem com a composição semântica.

Cobertura

A cobertura (*recall*), calculada com base na matriz de confusão, mede a quantidade de respostas corretas que foram recuperadas pelo modelo. Enquanto a precisão traz uma visão focada nas saídas positivas geradas pelo modelo, a cobertura olha mais para os casos positivos presentes nos dados de avaliação. Desta forma, a cobertura pode ser calculada como:

$$Cobertura = \frac{VP}{VP + FN} \tag{4.4}$$

Ao considerar a segmentação de palavras, a cobertura mede a porcentagem de segmentações que deveriam ser geradas pelo modelo e que foram geradas corretamente. Assim, uma alta cobertura indica que, pelo menos, os segmentos morfológicos estão sendo realizados, enquanto uma baixa cobertura indica o contrário, ou seja, não há separação de morfemas.

Para exemplificar a diferença entre uma cobertura alta e baixa, considere, novamente, a palavra *inflitradas* e sua segmentação `infiltr|ada|s`, que espera como resposta os rótulos $[0, 0, 0, 0, 0, 0, 1, 0, 0, 1]$. No caso de um segmentador em nível de caracteres, onde todos os rótulos serão positivos, não existirão casos de FN, resultando em uma cobertura de 100%. Já para o caso de segmentação em nível de palavras, em que nenhum caso de VP será identificado, o resultado será uma cobertura de 0%.

Assim como a precisão necessitou de um tratamento específico, para contornar os casos que representam a ativação da rota de armazenamento em um modelo de processamento morfológico, a cobertura também tratará desses casos. Portanto, palavras inteiras, que deveriam retornar uma cobertura de 0%, serão tratadas como casos positivos e retornarão uma

cobertura de 100%. Esse tratamento permite que as segmentações $[0, 0, 0, 0, 0, 0, 1, 0, 0, 1]$ e $[0, 0, 0, 0, 0, 0, 0, 0, 0, 0]$ sejam consideradas corretas.

Embora a cobertura considere apenas os casos em que a resposta esperada é 1, como a avaliação semântica considera duas possibilidades de respostas, uma para cada rota de processamento (armazenamento ou decomposição), os resultados de cobertura podem diferir da avaliação completa.

Medida F1

A precisão traz uma avaliação do ponto de vista da confiança que podemos ter no modelo quando ele detecta um caso como positivo, enquanto a cobertura nos traz uma visão do ponto de vista dos dados, mostrando a quantidade de casos corretos que estão sendo recuperados. Cada uma dessas métricas foca em diferentes tipos de erros: precisão em FP e cobertura em FN. A medida F1 surge como uma forma de balancear esses dois tipos de erros ao considerar a média harmônica entre precisão e cobertura, calculada da seguinte forma:

$$F1 = 2 \times \frac{Precisão \times Cobertura}{Precisão + Cobertura} \tag{4.5}$$

4.2 Corpus de Pré-Treinamento

A seguir, é apresentado o Corpus Carolina, utilizado para o pré-treinamento dos modelos Qwen-PT.

4.2.1 Corpus Carolina

Desenvolvido com foco em usos acadêmicos nas áreas de linguística e inteligência artificial, o Corpus Carolina (Crespo *et al.*, 2023) é um corpus aberto composto por textos do Português Brasileiro extraídos da web. Para cada texto extraído da internet, foram incluídas suas informações de proveniência e tipologia. Por se tratar de um trabalho que está em contínuo desenvolvimento, diversas versões do corpus já foram publicadas. No desenvolvimento deste trabalho, foi utilizada a versão 2.0.1 por ser a versão mais recente disponível. Os dados podem ser acessados na plataforma do Hugging Face[9] e na área de downloads de seu site.[10]

Além de permitir o uso em sua forma completa, o Corpus Carolina é dividido em sete taxonomias que possibilitam a seleção de textos mais específicos, de acordo com seus objetivos de comunicação: (dat) bases de dados e outros corpora; (jud) textos judiciais; (leg) textos legislativos; (pub) domínio público; (soc) mídias sociais; (uni) domínio universitário; (wik) wikis. Ao todo, o Corpus Carolina é formado por 2108999 instâncias, totalizando 15 GB de textos e metadados. Os tamanhos de cada tipologia são apresentados na Tabela 4.8.

[9] Disponível em: https://huggingface.co/datasets/carolina-c4ai/corpus-carolina

[10] Disponível em: https://sites.usp.br/corpuscarolina/

Código	Taxonomia	Instâncias	Tamanho
wik	Wikis	957501	5.3 GB
dat	Bases de dados e outros Corpora	1074032	4.3 GB
leg	Textos Legislativos	3982	4.2 GB
jud	Textos Jurídicos	38187	1 GB
uni	Domínio Universitário	26409	162 MB
soc	Mídias Sociais	8862	49 MB
pub	Domínio Público	26	4.5 MB
	Total	**2108999**	**15 GB**

Tabela 4.8: *Tamanho e número de instâncias de cada taxonomia presente no Corpus Carolina. Os dados apresentados referem-se à versão 2.0.1.*

4.3 Avaliação Conjunta

Nesta seção, são apresentadas as bases dados utilizadas para ajuste fino e avaliação dos modelos pré-treinados, comumente utilizadas em outros trabalhos da literatura, permitindo melhor comparação dos resultados obtidos com a literatura.

4.3.1 ASSIN e ASSIN 2

ASSIN (E. R. Fonseca *et al.*, 2016) e ASSIN 2 (Real, E. Fonseca *et al.*, 2020) são dois corpus com pares de sentenças anotadas manualmente para as tarefas de Inferência Textual (RTE - *Recognizing Textual Entailment*) e Similaridade Semântica (STS - *Semantic Textual Similarity*).

A base do ASSIN é formada por textos extraídos de notícias, utilizando modelos *Latent Dirichlet Allocation* para encontrar pares de sentenças com diferentes graus de similaridade. Composta por 10000 pares igualmente divididos entre Português Brasileiro e Português Europeu, as sentenças foram anotadas manualmente para as duas tarefas e distribuídos em subconjuntos de treinamento, teste e validação (ver Tabela 4.9). A Similaridade Semântica (STS) é uma tarefa de regressão, com rótulos variando entre 1 e 5, indicando o grau de similaridade entre as duas sentenças. Para a tarefa de Inferência Textual (RTE), uma tarefa de classificação multiclasse, foram utilizados os rótulos *entailment*, *paraphrase* ou *none*, indicando se o par de sentenças representa uma implicação, paráfrase ou relação neutra, respectivamente.

O corpus do ASSIN 2 traz algumas simplificações em seu processo de desenvolvimento. Sua construção foi baseada no SICK-BR (Real, A. Rodrigues *et al.*, 2018), que contém apenas textos em Português Brasileiro e apresenta fenômenos linguísticos mais simples. A tarefa de Inferência Textual foi simplificada para uma tarefa de classificação binária, utilizando os rótulos *entailment* e *non-entailment* para indicar a presença da implicação ou não.

Nos dois corpus, foram mantidas as mesmas métricas de avaliação, sendo *F1 Score* para a tarefa de Inferência Textual (classificação) e as medidas de Correlação de Pearson e o Erro Quadrático Médio (MSE - *Mean Squared Error*) para a tarefa de Similaridade Semântica (regressão).

Corpus	Treino	Teste	Validação	**Total**
ASSIN	5,000	1,000	4,000	10,000
ASSIN 2	6,500	500	2,448	9,448

Tabela 4.9: *Distribuição dos dados dos corpus ASSIN e ASSIN 2.*

4.3.2 HateBR

Motivado pela crescente hostilidade nas redes sociais e com o objetivo de disponibilizar dados para auxiliar em pesquisas sobre detecção de linguagem ofensiva e discursos de ódio, HateBR (Vargas *et al.*, 2022) é um corpus com 7000 comentários extraídos do Instagram.[11] Os comentários foram extraídos de contas públicas de políticos brasileiros e manualmente anotados por especialistas em 3 camadas de hostilidade.

A primeira camada de anotação corresponde à detecção de linguagem ofensiva, uma tarefa de classificação binária que busca identificar se um comentário apresenta linguagem ofensiva ou não. Nesta primeira camada, os dados foram balanceados, com 3500 comentários apresentando algum tipo de linguagem ofensiva. Para a segunda camada, o processo de anotação utilizou apenas os comentários com linguagem ofensiva (3500) para separá-los em 3 níveis de ofensividade: altamente, moderadamente e levemente ofensivo. O terceiro nível de anotação corresponde aos tipos de discurso de ódio, caracterizados por comentários ofensivos direcionados a grupos específicos por conta de alguma característica comum, como física, religiosa ou outra. As estatísticas sobre a anotação dos dados são apresentadas na Tabela 4.10.

Nível	Classe	Exemplos
1	Ofensivo	3500
	Não Ofensivo	3500
	total	*7000*
2	Leve	1678
	Moderado	1044
	Alto	778
	total	*3500*
3	Partidarismo	496
	Sexismo	97
	Intolerância Religiosa	47
	Apologia à Ditadura	32
	Gordofobia	27
	Homofobia	17
	Racismo	8
	Antisemitismo	2
	Xenofobia	1
	total	*727*

Tabela 4.10: *Distribuição dos dados do corpus HateBR por nível de anotação.*

[11] https://www.instagram.com/

Originalmente, os dados do HateBR foram disponibilizados como um conjunto único, sem apresentar uma separação previamente definida entre dados para treino, validação e teste. Por conta disso, neste trabalho, foram utilizados os dados disponibilizados em um repositório do HuggingFace,[12] que disponibiliza os dados já separados, facilitando a comparação com outros trabalhos da literatura que também utilizam essa mesma divisão (Corrêa, Falk *et al.*, 2024).

Além da tarefa de detecção de linguagem ofensiva, que utiliza as anotações da primeira camada, é possível considerar todos os tipos de discurso de ódio como casos positivos em uma tarefa de detecção de discurso de ódio e confrontá-los com os outros casos de linguagem ofensiva, conforme realizado por Vargas *et al.* (2022). A distribuição dos dados de cada tarefa é apresentada nas Tabelas 4.11 e 4.12, respectivamente. Como alguns comentários foram anotados com mais de um tipo de discurso de ódio, o total de casos de discurso de ódio apresentados na Tabela 4.12 é menor que o total de casos apresentados na Tabela 4.10.

	Ofensivo	Não Ofensivo	Total
Treino	2240	2240	4480
Validação	560	560	1120
Teste	700	700	1400
Total	3500	3500	7000

Tabela 4.11: *Distribuição dos dados do HateBR para a tarefa de detecção de linguagem ofensiva.*

	Ódio	Ofensivo	Total
Treino	478	1762	2240
Validação	95	465	560
Teste	129	571	700
Total	702	2798	3500

Tabela 4.12: *Distribuição dos dados do HateBR para a tarefa de detecção de discurso de ódio*

[12] Disponível em: https://huggingface.co/datasets/ruanchaves/hatebr

Capítulo 5

Experimentos

Este trabalho busca avaliar a hipótese de que a presença de segmentos morfologicamente coerentes, nos segmentos de entrada, melhora a capacidade de generalização dos modelos de linguagem (LLMs) no contexto da língua portuguesa. A literatura nos mostra que um texto pode ser segmentado de diferentes formas utilizando o mesmo vocabulário e que duas segmentações distintas são entendidas, pelo modelo, como entradas completamente diferentes (Kudo, 2018). Uma possibilidade de melhorar este cenário é induzir o modelo a uma segmentação mais próxima de morfemas para melhorar a performance dos LLMs (Hofmann *et al.*, 2021). Neste sentido, Bostrom e Durrett (2020) mostram que o *Unigram* é uma opção mais eficiente que o *BPE*.

A hipótese de pesquisa deste trabalho será avaliada em duas etapas, apresentadas nas seções a seguir. Na primeira etapa, na seção 5.1, será realizada uma comparação direta entre os modelos de segmentação *Unigram* e *Byte Pair Encoding*, com o treinamento de novos segmentadores (*tokenizers*) para a avaliação da presença de segmentos morfologicamente coerentes. Para isso, será utilizado o MorphEval-PT, o método de avaliação proposto neste trabalho e apresentado na seção 4.1. A segunda parte, descrita na seção 5.2, busca avaliar os impactos da presença de segmentos morfologicamente coerentes por meio do pré-treinamento de novos modelos de linguagem, comparando a performance após serem ajustados às bases de avaliação conjunta (ver seção 4.3). Desta forma, espera-se identificar se a presença de segmentos dotados de semântica se traduz em resultados melhores.

5.1 Avaliando a presença de segmentos semânticos

Conforme modelos psicolinguísticos de processamento morfológico (Seção 3.1.2), o significado de uma palavra pode ser construído de duas formas: (i) pela rota de armazenamento ou (ii) pela rota de decomposição. Este mesmo mecanismo de construção de significado pode ser encontrado nos segmentadores dos modelos de linguagem baseados em sub-palavras, mesmo que, ao decompor uma palavra, as partes não representem morfemas (Hofmann *et al.*, 2021).

Tomando como base a relação entre segmentadores de LLMs e os modelos psicolinguísticos de processamento morfológico, os experimentos descritos nesta seção buscam

analisar a capacidade dos segmentadores dos modelos de linguagem, disponíveis para o Português Brasileiro, na produção de segmentos morfologicamente coerentes e, desta forma, avaliar se eles se aproximam de um modelo de processamento morfológico.

Conforme exemplificado na seção 4.1.3, os dados gerados possuem algumas limitações e não representam uma segmentação morfológica propriamente dita, sendo mais adequados para a identificação e validação de prefixos e sufixos. Com isso em mente, visando o melhor aproveitamento dos dados disponíveis, mostra-se mais produtivo avaliar a capacidade de cada segmentador em identificar esses afixos do que considerar uma segmentação morfológica completa de cada palavra. Desta forma, serão realizadas duas formas de avaliação: *semântica* e *completa*.

A avaliação chamada de semântica é motivada pelos modelos de processamento morfológico e considera as duas rotas durante a avaliação. No caso dos segmentadores dos modelos de linguagem, a rota de decomposição é ativada ao dividir uma única palavra em sub-palavras. Para avaliar essa rota, serão considerados como corretos apenas os segmentos que representam morfemas. Por conta da limitação da base de dados, apenas os afixos indicados serão considerados na avaliação da rota de decomposição. Já a rota de armazenamento, ativada quando a palavra não é dividida em sub-palavras, permite que palavras inteiras sejam consideradas corretas. Em outras palavras, a avaliação semântica permite que, para uma entrada da base de dados, duas respostas sejam consideradas corretas: a segmentação dos afixos e da palavra inteira.

Também será feita uma avaliação, chamada de *completa*, que desconsidera as limitações presentes nos dados, tratando as segmentações de morfemas disponíveis como se estas fossem completas e corretas. Esta avaliação desconsidera os modelos de processamento morfológico, tratando apenas a segmentação disponível como esta fosse linguisticamente correta.

5.1.1 Modelos de Segmentação

Modelos de segmentação são responsáveis pela padronização e transformação de textos, deixando-os prontos para o processamento por modelos de linguagem. Diferentes modelos de linguagem possuem diferentes formas de preparar o texto, mas normalmente seguem a mesma sequência de pré-processamento[1]: (a) normalização; (b) pré-segmentação; (c) modelo de segmentação; e (d) pós-processamento; Para avaliar de forma mais adequada a diferença entre os algoritmos *Unigram* e *Byte Pair Encoding* e verificar qual deles é capaz de produzir um melhor alinhamento com segmentos semânticos, apenas o modelo de segmentação (etapa c) foi modificado durante o treinamento dos novos segmentadores.

O processo de normalização é responsável pela limpeza do texto puro, tornando-o menos aleatório. Nesta etapa, foram aplicadas as operações para a remoção de espaços em branco nas extremidades do texto (*strip*), seguida pela normalização Unicode NFC, que apresentou melhores resultados em avaliações preliminares.

A pré-segmentação corresponde à identificação de "palavras", definindo os limites máximos para a criação de segmentos em nível de sub-palavra. Nesta etapa, é comum

[1] https://huggingface.co/docs/tokenizers/pipeline

utilizar a delimitação de palavras por espaços em branco. Neste trabalho, além desta separação em espaços em branco, também foi utilizada a representação em nível de *bytes* (Radford, Wu *et al.*, 2019), que substitui todos os *bytes* de uma palavra por uma representação correspondente. Esta pré-segmentação é utilizada para tratar e evitar o aparecimento de palavras desconhecidas. Embora esta operação seja comumente aplicada ao *Byte Pair Encoding*, também foi aplicada ao *Unigram*.

A etapa do modelo de segmentação corresponde à aplicação das regras de segmentação ao texto pré-segmentado, transformando cada "palavra" em uma sequência de números que indicam os segmentos do vocabulário. Esta é a única parte que precisa ser treinada em um corpus, permitindo a construção de um vocabulário e o aprendizado das regras de segmentação. Os dois modelos de segmentação utilizaram o alfabeto de *bytes* como vocabulário básico. No caso do *Byte Pair Encoding*, o vocabulário básico é utilizado como vocabulário inicial, permitindo que sequências de *bytes* maiores possam ser incorporadas ao vocabulário de acordo com suas frequências. No caso do *Unigram*, o vocabulário básico é utilizado para evitar que estes sejam excluídos do vocabulário final durante o treinamento.

O pós-processamento é a última etapa do pipeline, responsável pela transformação final e formatação da sequência de segmentos de acordo com um modelo. É nesta etapa que os segmentos especiais são inseridos ao texto de entrada. Neste trabalho, foram inseridos os segmentos especiais `[EOS]` e `[SEP]` para indicar o fim e a separação de sentenças, respectivamente, que serão importantes para o treinamento dos modelos de linguagem posteriormente.

Com o processo de segmentação definido, é necessário treinar os modelos para que o vocabulário de segmentos seja construído. Neste processo de treinamento, o tamanho do vocabulário é o único hiperparâmetro a ser configurado. Cada modelo foi treinado até atingir vocabulários de tamanhos 5k, 8k, 10k, 30k e 50k. Todos os modelos foram treinados com o corpus Carolina (seção 4.2.1) e estão publicamente disponíveis em uma coleção no hub do Hugging Face.[2] Os resultados relacionados à capacidade de gerar segmentos semânticos são apresentados na seção 5.1.2.

5.1.2 Resultados

Conforme explicado na seção 4.1.4, sobre as métricas de avaliação, a avaliação da presença de morfemas pode ser realizada de duas formas: *semântica* e *completa*. A avaliação *completa* indica que não houve nenhum tratamento referente às limitações presentes nos dados e que a segmentação apresentada estava "correta" e, portanto, qualquer segmentação gerada pelo modelo foi considerada durante a construção da matriz de confusão. Já a avaliação *semântica* busca avaliar a semelhança entre os segmentadores e os modelos psicolinguísticos de processamento morfológico e, com isso, caracterizar processos de composicionalidade semântica. Desta forma, os resultados apresentados na avaliação *semântica* consideram apenas a segmentação dos afixos ou de palavra inteira, representando a ativação das rotas de decomposição ou armazenamento. Os resultados obtidos para os afixos de derivação são apresentados na Tabela 5.1 e os afixos de flexão são apresentados na Tabela 5.2. Os resultados apresentados estão separados por processo morfológico, de acordo

[2] Disponíveis em: https://hf.co/collections/guilhermelmello/tokenizers-qwen-pt

com as palavras e segmentações presentes em cada arquivo dos dados do MorphEval-PT (Sessão 4.1).

Em relação ao número de palavras inteiras, que representam a ativação da rota de armazenamento, é possível observar que o BPE inclui poucas palavras inteiras para vocabulários menores e, à medida que o tamanho do vocabulário aumenta, uma quantidade cada vez maior de palavras inteiras é armazenada. Esse comportamento do BPE é esperado, dada a natureza de seu algoritmo *bottom-up* de construção do vocabulário. O *Unigram* também apresenta um comportamento semelhante, porém, o aumento no tamanho do vocabulário resulta em um acréscimo muito menor na quantidade de palavras inteiras, indicando que o algoritmo tende a manter uma segmentação que favorece a composicionalidade semântica.

Na avaliação semântica, a métrica de precisão mostra a qualidade dos segmentos sugeridos, indicando o quanto as delimitações entre os segmentos realizadas se aproximam das delimitações dos morfemas. Neste sentido, o BPE se mostrou mais adequado, em especial ao considerar os afixos de flexão (Tabela 5.2), variando em uma precisão entre 10% a 30% melhor que o Unigram. Vale ressaltar que a vantagem do BPE, neste caso, não se deve pela maior quantidade de palavras inteiras em seu vocabulário. Isso pode ser justificado ao observar, na Tabela 5.1, em que o BPE com vocabulário de 5k segmentos obteve 61,77% de precisão para os afixos de derivação com apenas 0,77% de palavras inteiras produzidas. Para obter uma precisão de 61,07%, o Unigram precisou de um vocabulário de 50k segmentos, gerando 5,29% de palavras inteiras.

A análise da cobertura indica se as delimitações entre os morfemas estão sendo recuperada pelos modelos. Para os afixos de derivação (Tabela 5.1), o Unigram apresentou valores de cobertura expressivamente maiores que o BPE, indicando maior capacidade em criar segmentos de acordo com as delimitações entre morfemas. Enquanto isso, para os afixos de flexão (Tabela 5.2), o BPE apresentou valores ligeiramente maiores. Um padrão que surge para a cobertura é uma relação inversa ao tamanho do vocabulário: a cobertura diminui enquanto o tamanho do vocabulário aumenta. A única exceção acontece para o BPE com vocabulário de 50k para os afixos de derivação (Tabela 5.1). Porém, a análise da cobertura requer um cuidado especial, já que uma baixa cobertura pode indicar uma maior taxa de compressão quando associada a uma alta precisão. O cenário oposto, quando uma alta cobertura está associada a uma baixa precisão, pode indicar que muitos segmentos estão sendo criados de forma desnecessária, algo que pode estar acontecendo com o Unigram para os afixos de flexão (Tabela 5.2). Esse mesmo cuidado também deve ser tomado ao interpretar a medida de F1, que mostra um balanceamento entre a precisão e a cobertura, as quais apresentam tendências diferentes em relação ao tamanho do vocabulário. Entretanto, os vocabulários de 8k foram selecionados para a realização dos experimentos subsequentes por apresentarem um vocabulário compacto, melhores valores de F1 e produzirem poucas palavras inteiras.

Além da capacidade de identificar as delimitações entre morfemas, outra característica importante a ser analisada é a presença de morfemas nos vocabulários de cada segmentador. Como é possível observar na Tabela 5.3, conforme esperado, o número de afixos presentes em cada vocabulário aumenta de acordo com que o conjunto de segmentos conhecidos aumenta. Porém, mais uma vez, o BPE se destaca por incorporar mais afixos em seus vocabulários. Ao comparar diretamente a quantidade de afixos presentes em

Modelo	Vocabulário		Completa			Semântica			Palavras Inteiras
			Precisão	Cobertura	F1	Precisão	Cobertura	F1	
BPE		5k	16.19%	45.13%	23.83%	61.77%	45.90%	52.67%	89 (0.77%)
		8k	16.36%	41.39%	23.45%	63.95%	43.34%	51.66%	224 (1.95%)
		10k	16.38%	39.43%	23.15%	64.20%	42.33%	51.02%	333 (2.90%)
		15k	16.95%	37.06%	23.26%	66.65%	41.63%	51.25%	526 (4.57%)
		30k	17.56%	31.92%	22.65%	70.34%	41.49%	52.20%	1101 (9.57%)
		50k	18.02%	27.48%	21.76%	75.73%	43.07%	**54.91%**	1792 (15.58%)
Unigram		5k	13.57%	67.14%	22.58%	47.03%	68.32%	55.71%	135 (1.17%)
		8k	15.47%	64.89%	24.98%	57.53%	66.59%	**61.73%**	195 (1.70%)
		10k	15.25%	58.90%	24.23%	57.94%	60.86%	59.36%	225 (1.96%)
		15k	16.36%	55.09%	25.23%	59.19%	57.62%	58.39%	291 (2.53%)
		30k	17.03%	49.54%	25.34%	59.21%	53.59%	56.26%	465 (4.04%)
		50k	19.94%	44.52%	27.54%	61.07%	49.80%	54.87%	608 (5.29%)
Qwen3 0.6B	BPE	150k	19.29%	45.86%	27.16%	64.49%	46.04%	53.73%	21 (0.18%)
Albertina 900m	Unigram	128k	24.25%	54.28%	33.52%	74.22%	55.20%	**63.32%**	106 (0.92%)
Albertina 100m	BPE	50k	16.55%	51.44%	25.04%	46.02%	51.53%	48.62%	11 (0.10%)
PeLLE	BPE	50k	16.96%	42.67%	24.27%	51.24%	43.27%	46.92%	68 (0.59%)
BERTimbau	WordPiece	30k	22.06%	39.41%	28.29%	71.16%	46.89%	56.53%	861 (7.49%)
mBERT-cased	WordPiece	120k	21.36%	44.20%	28.80%	62.72%	47.04%	53.76%	326 (2.83%)
TeenyTinyLlama	BPE	32k	18.85%	34.24%	24.32%	70.74%	42.41%	53.03%	940 (8.17%)

Tabela 5.1: *Avaliação na base de derivações. Total de palavras: 11501.*

Modelo	Vocabulário		Completa			Semântica			Palavras Inteiras
			Precisão	Cobertura	F1	Precisão	Cobertura	F1	
BPE		5k	20.53%	58.07%	30.33%	51.44%	58.26%	54.64%	590 (0.20%)
		8k	21.60%	55.80%	31.15%	53.94%	56.20%	55.04%	1207 (0.40%)
		10k	22.16%	54.83%	31.57%	54.98%	55.38%	55.18%	1677 (0.56%)
		15k	23.21%	52.39%	32.17%	57.25%	53.32%	55.21%	2804 (0.94%)
		30k	25.00%	48.95%	33.10%	58.61%	51.11%	54.60%	6467 (2.16%)
		50k	27.05%	46.18%	34.12%	62.47%	49.89%	**55.48%**	11094 (3.70%)
Unigram		5k	10.09%	52.33%	16.92%	30.00%	52.63%	**38.22%**	926 (0.31%)
		8k	10.14%	47.89%	16.73%	29.16%	48.36%	36.38%	1451 (0.48%)
		10k	10.37%	46.09%	16.93%	29.25%	46.67%	35.96%	1796 (0.60%)
		15k	10.71%	43.19%	17.17%	29.16%	44.02%	35.08%	2545 (0.85%)
		30k	10.95%	38.85%	17.09%	30.60%	40.08%	34.71%	3792 (1.26%)
		50k	11.54%	33.31%	17.14%	27.90%	35.00%	31.05%	5204 (1.74%)
Qwen3 0.6B	BPE	150k	25.90%	64.14%	36.90%	58.28%	64.47%	**61.22%**	1020 (0.34%)
Albertina 900m	Unigram	128k	17.62%	42.52%	24.91%	37.30%	43.12%	40.00%	1859 (0.62%)
Albertina 100m	BPE	50k	22.76%	64.86%	33.69%	49.01%	65.03%	55.90%	526 (0.18%)
PeLLE	BPE	50k	9.30%	21.97%	13.07%	26.36%	22.59%	24.33%	1903 (0.63%)
BERTimbau	WordPiece	30k	13.24%	26.33%	17.62%	29.14%	28.22%	28.67%	5765 (1.92%)
mBERT-cased	WordPiece	120k	10.98%	24.03%	15.07%	26.29%	25.10%	25.68%	3277 (1.09%)
TeenyTinyLlama	BPE	32k	27.69%	54.85%	36.80%	60.76%	56.78%	58.70%	5819 (1.94%)

Tabela 5.2: *Avaliação na base de flexões. Total de palavras: 299807.*

cada vocabulário, o BPE apresenta cerca de 20% a mais que o Unigram para os afixos de derivação e cerca de 30% a mais para os sufixos de flexão. Essa diferença se mantém ao variar o tamanho dos vocabulários.

Ao considerar alguns modelos disponíveis na literatura, Albertina apresenta os melhores resultados, tanto em precisão quanto em F1. Porém, um dos segmentadores se mostra bom para processos de derivação, enquanto o outro se mostra mais adequado para os casos de flexão. Embora a família de modelos Albertina (J. Rodrigues *et al.*, 2023; Santos, J. Rodrigues *et al.*, 2024) tenha sido desenvolvida para o Português, os autores utilizaram a estratégia de pré-treinamento continuado tomando como base os modelos DeBERTa (He, X. Liu *et al.*, 2021), incluindo os vocabulários, originalmente treinados com textos em Inglês. Em relação ao baixo percentual de palavras inteiras, mesmo com um vocabulário relativamente grande, por terem sido treinados com textos em Inglês, os segmentadores dos modelos Albertina impedem que a rota de armazenamento seja utilizada. Corrêa, Sen *et al.* (2025) apresentam uma discussão que corrobora com esse comportamento observado, indicando que segmentadores tendem a precisar de um contexto maior quando utilizados em uma língua diferente da qual foram treinados. Porém, mesmo sendo treinado com dados em Inglês, o modelo Albertina com 900M de parâmetros utiliza um vocabulário que contém uma quantidade considerável de afixos presentes na língua portuguesa.

5.2 Impacto de Segmentos Semânticos

O impacto da presença de segmentos semânticos é avaliado com o ajuste fino dos modelos de linguagem *Qwen-PT-Unigram* e *Qwen-PT-BPE* em avaliações conjuntas (*downstream tasks*). A seguir, são apresentados os modelos pré-treinados, tomando como base os resultados obtidos anteriormente, e as tarefas utilizadas para a avaliação dos modelos.

5.2.1 Qwen-PT: Pré-Treinamento de Modelos de Linguagem

Para que a hipótese de pesquisa pudesse ser avaliada de forma mais precisa, foram treinados dois modelos de linguagem de forma idêntica, chamados *Qwen-PT-Unigram* e *Qwen-PT-BPE*, com o modelo de segmentação sendo a única diferença entre eles. Dentre os diferentes tamanhos de vocabulário disponíveis, foram utilizados os vocabulários com 8k segmentos, devido aos resultados obtidos na avaliação de segmentação semântica (seção 5.1.2) e por apresentarem um vocabulário compacto, resultando em uma quantidade menor de parâmetros na camada de *embedding* e, consequentemente, menor tempo de treinamento e ajuste-fino dos modelos.

A arquitetura dos modelos Qwen3 (Yang *et al.*, 2025) é baseada no *decoder* do *Transfomers* (Vaswani *et al.*, 2017) e requer o treinamento para Modelos de Linguagem Causal (CLM - *Causal Language Modeling*). Nesta configuração, o modelo recebe uma sequência como entrada e tenta gerar o próximo segmento como saída. A arquitetura do Qwen3 tem apresentado bons resultados na literatura, permitindo o desenvolvimento de modelos menores, mas eficientes, que podem requerem menor custo computacional para a avaliação da hipótese desta pesquisa. Cada modelo foi treinado por 10 épocas, utilizando os dados da versão 2.0.1 do Corpus Carolina (Crespo *et al.*, 2023), preparados em janelas de 1024 segmentos. Para a preparação da base, todas as sequências foram concatenadas utilizando

Modelo	Vocabulário		Derivação Prefixos	Derivação Sufixos	Derivação Afixos	Flexão Sufixos	Afixos Total
BPE		5k	45 (23.94%)	102 (51.00%)	147 (37.89%)	61 (37.65%)	208 (37.82%)
		8k	56 (29.79%)	116 (58.00%)	172 (44.33%)	69 (42.59%)	241 (43.82%)
		10k	60 (31.91%)	120 (60.00%)	180 (46.39%)	73 (45.06%)	253 (46.00%)
		15k	74 (39.36%)	129 (64.50%)	203 (52.32%)	80 (49.38%)	283 (51.45%)
		30k	97 (51.60%)	133 (66.50%)	230 (59.28%)	86 (53.09%)	316 (57.45%)
		50k	117 (62.23%)	140 (70.00%)	257 (66.24%)	91 (56.17%)	348 (63.27%)
Unigram		5k	28 (14.89%)	38 (19.00%)	66 (17.01%)	16 (09.88%)	82 (14.91%)
		8k	39 (20.74%)	50 (25.00%)	89 (22.94%)	20 (12.35%)	109 (19.82%)
		10k	48 (25.53%)	58 (29.00%)	106 (27.32%)	20 (12.35%)	126 (22.91%)
		15k	67 (35.64%)	62 (31.00%)	129 (33.25%)	23 (14.20%)	152 (27.64%)
		30k	86 (45.74%)	68 (34.00%)	154 (39.69%)	39 (24.07%)	193 (35.09%)
		50k	101 (53.72%)	79 (39.50%)	180 (46.39%)	43 (26.54%)	223 (40.55%)
Qwen3 0.6B	BPE	150k	100 (53.19%)	112 (56.00%)	212 (54.64%)	74 (45.68%)	286 (52.00%)
Albertina 900m	Unigram	128k	115 (61.17%)	133 (66.50%)	248 (63.92%)	62 (38.27%)	310 (56.36%)
Albertina 100m	BPE	50k	85 (45.21%)	91 (45.50%)	176 (45.36%)	58 (35.80%)	234 (42.55%)
PeLLE	BPE	50k	147 (78.19%)	139 (69.50%)	286 (73.71%)	74 (45.68%)	360 (65.45%)
BERTimbau	WordPiece	30k	107 (56.91%)	146 (73.00%)	253 (65.21%)	97 (59.88%)	350 (63.64%)
mBERT-cased	WordPiece	120k	87 (46.28%)	154 (77.00%)	241 (62.11%)	80 (49.38%)	321 (58.36%)
TeenyTinyLlama	BPE	32k	53 (28.19%)	162 (81.00%)	215 (55.41%)	111 (68.52%)	326 (59.27%)

Tabela 5.3: *Estatísticas sobre a presença de afixos no vocabulário de cada segmentador. Os valores estão separados entre os tipos de afixos. Ao todo, os dados derivados da MorphyNet apresentam 162 sufixos de flexão e 388 afixos de derivação, sendo 188 prefixos e 200 sufixos, resultando em 550 afixos diferentes.*

o segmento especial `[SEP]` para indicar a separação entre sentenças. A construção das sequências de 1024 segmentos foi realizada em *batches* de 1000 sentenças. Como consequência, a última sequência de cada *batch* de dados acabaram resultando, possivelmente, em uma sequência menor que 1024 segmentos. Normalmente, esta sequência é eliminada desta fase de treinamento, evitando a introdução de *paddings* (`[PAD]`). Neste trabalho, essas sequências foram mantidas e utilizadas para introduzir os segmentos de final de sentença (`[EOS]`) no pré-treinamento dos modelos. O segmento de final de sentença foi incluído apenas em sentenças com *paddings*, introduzidos à esquerda, para refletir o cenário de classificação de sentenças em que os modelos serão utilizados. Por se tratar de um *decoder*, apenas o último segmento contará com informações sobre toda a sentença e, ao introduzir o segmento `[EOS]` ao final das sentenças, poderá ser utilizado como representação para problemas de classificação.

O menor modelo disponibilizado pela família Qwen3 contém cerca de 600 milhões de parâmetros.[3] Como os modelos Qwen-PT utilizam um vocabulário consideravelmente menor, é natural que o total de parâmetros seja menor, decorrente da menor quantidade de parâmetros na camada de *embedding*. Em experimentos iniciais, ao utilizar as mesmas dimensões do Qwen3 de 600 milhões de parâmetros, foram obtidos resultados muito abaixo dos esperados. Uma das possibilidades para a obtenção desses resultados é a pouca quantidade de dados utilizados para a quantidade de parâmetros presentes no modelo (Kaplan *et al.*, 2020). Por conta disso, o número de camadas escondidas (L) foi reduzido de 28 para 12, seguindo o mesmo valor normalmente encontrado em outros modelos de tamanho *base*. Com os demais parâmetros mantidos (H=1024 e A=16), os modelos Qwen-PT-Base[4] resultaram em cerca de 200 milhões de parâmetros totais.

5.2.2 Resultados: Avaliação Conjunta

Os dois modelos foram avaliados em diferentes tarefas de avaliação conjunta. Os resultados são apresentados nas seções a seguir. Para cada tarefa, foram realizadas buscas de hiperparâmetros, variando os valores para os tamanhos de *batch* e para a taxa de aprendizado. Para a busca de hiperparâmetros, os modelos foram treinados por 5 épocas, selecionando os parâmetros que produziram as melhores métricas de cada tarefa. Com os valores definidos, os modelos foram inicializados de forma aleatória e novamente treinados por 10 épocas, selecionando o melhor modelo dentre todas as épocas.

Para realizar o ajuste-fino dos modelos baseados na arquitetura *decoder*, Qwen-PT e TeenyTinyLlama, foram utilizadas as representações do segmento especial `[EOS]` como entrada para a camada de classificação, eliminando o uso de técnicas de engenharia de prompt e a introdução de novas variáveis que pudessem influenciar os resultados e a comparação entre os modelos, tornando a comparação entre os segmentadores BPE e *Unigram* mais justa.

[3] https://huggingface.co/Qwen/Qwen3-0.6B-Base

[4] Disponíveis em https://huggingface.co/collections/guilhermelmello/qwen-pt

ASSIN e ASSIN 2

A Tabela 5.4 mostra os resultados obtidos nas tarefas de Inferência Textual (RTE - *Recognizing Textual Entailment*) e de Similaridade Semântica (STS - *Semantic Textual Similarity*) para as bases ASSIN e ASSIN 2. Como é possível observar, o BPE apresentou melhores resultados em todas as tarefas, obtendo um ganho médio de 2,65% em relação ao *Unigram*.

Além disso, é possível observar que os melhores resultados foram obtidos pelos modelos de arquitetura *encoder*. Porém, os modelos Qwen-PT apresentam resultados melhores quando comparados aos modelos TeenyTinyLlama, que também são arquiteturas *decoder* treinadas do zero para o Português Brasileiro.

Todos os resultados foram obtidos após uma busca de hiperparâmetros, considerando *batches* de tamanhos 8, 16 e 32, e as taxas de aprendizado 5e-3, 5e-4, 5e-5 e 5e-6. Alguns dos resultados reportados diferem ligeiramente dos valores reportados pelos trabalhos originais e podem ser decorrentes dos hiperparâmetros utilizados ou dos pesos aleatoriamente inicializados na camada de classificação.

	ASSIN		ASSIN 2		
Modelo	RTE	STS	RTE	STS	*avg*
Qwen-PT-Unigram	0.6826	0.7377	0.8537	0.7187	*0.7481*
Qwen-PT-BPE	0.7309	0.7454	0.8589	0.7635	*0.7746*
Albertina-100m	0.8081	0.8229	0.8792	0.7810	*0.8228*
BERTimbau-base	0.8172	0.7905	0.8991	0.7903	*0.8242*
BERTimbau-large	0.8254	0.6616	0.8941	0.7995	*0.7951*
TeenyTinyLlama-160m	0.6998	0.7110	0.8723	0.6119	*0.7237*
TeenyTinyLlama-460m	0.7279	0.6810	0.8799	0.6956	*0.7461*

Tabela 5.4: *Resultados obtidos para as tarefas de inferência textual (RTE) e similaridade (STS) das bases ASSIN e ASSIN 2, respectivamente medidas com Score F1 e a correlação de Pearson.*

5.2.3 HateBR

O HateBR apresenta sentenças um pouco maiores em relação ao ASSIN e ASSIN 2. Por conta disso, para a busca de hiperparâmetros, foram utilizados *batches* de tamanhos 4, 8 e 16, e as taxas de aprendizado 5e-3, 5e-4, 5e-5 e 5e-6. Os resultados obtidos para as tarefas de detecção de linguagem ofensiva e detecção de discurso de ódio são apresentados na Tabela 5.5.

Mais uma vez, o BPE apresentou melhores resultados do que o *Unigram*, contrariando os resultados obtidos por Bostrom e Durrett (2020). Para a tarefa de detecção de linguagem ofensiva, repetindo os mesmos padrões observados anteriormente, modelos de arquitetura *encoder* mostram-se ligeiramente melhores. Entretanto, esse comportamento não é observado para para a detecção de discurso de ódio. Conforme esperado, na média, modelos maiores apresentam um ganho de performance.

	HateBR		
Modelo	Ling. Ofensiva	Disc. de Ódio	*avg*
Qwen-PT-Unigram	0.8999	0.8585	*0.8792*
Qwen-PT-BPE	0.9157	0.8871	*0.9014*
Albertina-100m	0.8905	0.8428	*0.8666*
BERTimbau-base	0.9142	0.8627	*0.8884*
BERTimbau-large	0.9249	0.8596	*0.8922*
TeenyTinyLlama-160m	0.9071	0.8142	*0.8606*
TeenyTinyLlama-460m	0.9192	0.8683	*0.8937*

Tabela 5.5: *Resultados obtidos para as tarefas de detecção de linguagem ofensiva e detecção de discurso de ódio do HateBR, ambas medidas com F1.*

Capítulo 6

Conclusão

Motivado pelas teorias psicolinguísticas de processamento morfológico e pela capacidade dos LLMs baseados na arquitetura *Transformers* na criação de espaços semânticos, este trabalho explorou a hipótese de que um maior alinhamento do processo de segmentação (*tokenizer*) como uma sequência de morfemas (coerência morfológica) pode melhorar a qualidade semântica e a capacidade de generalização dos LLMs.

Para isso, inicialmente, tomando como base os modelos de processamento morfológico e os dados disponíveis na MorphyNet, foi desenvolvido um método para avaliar a presença de morfemas em diferentes segmentadores, chamado de MorphEval-PT. Embora limitado aos processos de derivação e flexão, permite entender de forma mais objetiva o quanto diferentes modelos de segmentação se aproximam de uma sequência de morfemas ao considerar o Português Brasileiro.

Embora a literatura mostre que o *Unigram* tem uma vantagem de performance em relação ao *Byte Pair Encoding* (Bostrom e Durrett, 2020), os resultados obtidos nas tarefas de classificação mostram que a simples substituição do BPE pelo *Unigram* não é suficiente. Consequentemente, algo a mais deve ser responsável para que esse ganho de performance exista. Neste trabalho, exploramos a possibilidade de que a coerência morfológica seja este algo a mais. Pelo uso do MorphEval-PT, foi possível observar que o BPE apresentou um vocabulário com uma maior quantidade de afixos (Tabela 5.3) e que sua segmentação, no contexto deste trabalho, tende a gerar uma maior coerência morfológica, o que pode ser observado pela maior precisão em relação ao *Unigram* (Tabelas 5.1 e 5.2).

Por conta disso, o método de avaliação de segmentadores MorphEval-PT, apresentado neste trabalho (Seção 4.1), se mostra uma importante ferramenta para o desenvolvimento de novos LLMs para o Português Brasileiro ao permitir que o modelo de segmentação seja desenvolvido e avaliado sem a necessidade de pré-treinamento do modelo, auxiliando no ganho de performance em um ponto de baixo custo computacional.

Conforme apresentado na Seção 4.1.3, os dados disponíveis pela MorphyNet possuem grandes limitações, dificultando uma avaliação mais aprofundada dos diferentes modelos de segmentação. Portanto, o desenvolvimento de uma base mais robusta se apresenta como um trabalho futuro. Além disso, são necessários experimentos mais extensivos,

utilizando novos conjuntos de dados que induzam um maior alinhamento entre segmentos e morfemas no desenvolvimento de novos segmentadores.

Referências

[Alencar *et al.* 2018] Leonel Figueiredo de Alencar, Bruno Cuconato e Alexandre Rademaker. "Morphobr: an open source large-coverage full-form lexicon for morphological analysis of portuguese". *Texto Livre: Linguagem e Tecnologia* 11.3 (2018), pp. 1–25 (citado na pg. 3).

[Bahdanau *et al.* 2015] Dzmitry Bahdanau, Kyung Hyun Cho e Yoshua Bengio. "Neural machine translation by jointly learning to align and translate". In: *3rd International Conference on Learning Representations, ICLR*. 2015 (citado na pg. 6).

[Batsuren *et al.* 2021] Khuyagbaatar Batsuren, Gábor Bella e Fausto Giunchiglia. "Morphynet: a large multilingual database of derivational and inflectional morphology". In: *Proceedings of the 18th SIGMORPHON Workshop on Computational Research in Phonetics, Phonology, and Morphology*. Association for Computational Linguistics, 2021, pp. 39–48. doi: 10.18653/v1/2021.sigmorphon-1.5. url: https://aclanthology.org/2021.sigmorphon-1.5/ (citado nas pgs. 3, 21–24).

[Batsuren *et al.* 2022] Khuyagbaatar Batsuren, Gábor Bella e Fausto Giunchiglia. "A large and evolving cognate database". *Language Resources and Evaluation* 56.1 (2022), pp. 165–189 (citado na pg. 22).

[Beesley e Karttunen 2003] Kenneth R Beesley e Lauri Karttunen. *Finite-state morphology*. CSLI Publications, 2003 (citado na pg. 3).

[Belinkov e Glass 2019] Yonatan Belinkov e James Glass. "Analysis methods in neural language processing: a survey". *Transactions of the Association for Computational Linguistics* 7 (abr. de 2019), pp. 49–72. issn: 2307-387X. doi: 10.1162/tacl_a_00254 (citado na pg. 5).

[Bengio *et al.* 2003] Yoshua Bengio, Réjean Ducharme, Pascal Vincent e Christian Janvin. "A neural probabilistic language model". *The Journal of Machine Learning Research* 3 (2003), pp. 1137–1155 (citado na pg. 5).

[Berti *et al.* 2025] Leonardo Berti, Flavio Giorgi e Gjergji Kasneci. *Emergent Abilities in Large Language Models: A Survey*. 2025. arXiv: 2503.05788 [cs.LG]. url: https://arxiv.org/abs/2503.05788 (citado na pg. 8).

[Bostrom e Durrett 2020] Kaj Bostrom e Greg Durrett. "Byte pair encoding is suboptimal for language model pretraining". In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. Association for Computational Linguistics, 2020. DOI: 10.18653/v1/2020.findings-emnlp.414 (citado nas pgs. i, iii, 2, 10, 35, 44, 47).

[Brown *et al.* 2020] Tom B. Brown *et al.* "Language models are few-shot learners" (2020). arXiv: 2005.14165 [cs.CL] (citado nas pgs. 7, 8).

[Cambria e White 2014] Erik Cambria e Bebo White. "Jumping nlp curves: a review of natural language processing research". *IEEE Computational Intelligence Magazine* 9 (2 mai. de 2014), pp. 48–57. ISSN: 1556-603X. DOI: 10.1109/MCI.2014.2307227 (citado na pg. 5).

[Cho *et al.* 2014] Kyunghyun Cho *et al.* "Learning phrase representations using RNN encoder–decoder for statistical machine translation". In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2014, pp. 1724–1734. DOI: 10.3115/v1/D14-1179 (citado na pg. 6).

[Clark *et al.* 2020] Kevin Clark, Minh-Thang Luong, Quoc V Le e Christopher D Manning. "Electra: pre-training text encoders as discriminators rather than generators". *arXiv preprint arXiv:2003.10555* (2020) (citado nas pgs. 7, 8).

[Collobert e Weston 2008] Ronan Collobert e Jason Weston. "A unified architecture for natural language processing: deep neural networks with multitask learning". In: *Proceedings of the 25th International Conference on Machine Learning*. ICML '08. New York, NY, USA: Association for Computing Machinery, 2008, pp. 160–167. ISBN: 9781605582054. DOI: 10.1145/1390156.1390177 (citado na pg. 5).

[Conneau, Khandelwal *et al.* 2020] Alexis Conneau, Kartikay Khandelwal *et al.* "Unsupervised cross-lingual representation learning at scale". In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, jul. de 2020, pp. 8440–8451. DOI: 10.18653/v1/2020.acl-main.747. URL: https://aclanthology.org/2020.acl-main.747/ (citado na pg. 9).

[Conneau e Lample 2019] Alexis Conneau e Guillaume Lample. "Cross-lingual language model pretraining". In: *Advances in Neural Information Processing Systems*. Vol. 32. Curran Associates, Inc., 2019 (citado nas pgs. 8, 9).

[Corrêa, Falk *et al.* 2024] Nicholas Kluge Corrêa, Sophia Falk, Shiza Fatimah, Aniket Sen e Nythamar De Oliveira. "Teenytinyllama: open-source tiny language models trained in brazilian portuguese". *Machine Learning with Applications* 16 (jun. de 2024), p. 100558. ISSN: 2666-8270. DOI: 10.1016/j.mlwa.2024.100558. URL: http://dx.doi.org/10.1016/j.mlwa.2024.100558 (citado nas pgs. 9, 34).

[Corrêa, Sen *et al.* 2025] Nicholas Kluge Corrêa, Aniket Sen, Sophia Falk e Shiza Fatimah. "Tucano: advancing neural text generation for portuguese". *Patterns* 6.11 (2025), p. 101325. issn: 2666-3899. doi: https://doi.org/10.1016/j.patter.2025.101325. url: https://www.sciencedirect.com/science/article/pii/S2666389925001734 (citado nas pgs. 9, 10, 41).

[Crespo *et al.* 2023] Maria Clara Ramos Morales Crespo *et al. Carolina: a General Corpus of Contemporary Brazilian Portuguese with Provenance, Typology and Versioning Information*. 2023. arXiv: 2303.16098 [cs.CL] (citado nas pgs. 31, 41).

[Creutz e Linden 2004] Mathias Johan Philip Creutz e Bo Krister Johan Linden. "Morpheme segmentation gold standards for finnish and english". English. In: *Publications in Computer and Information Science*. Finland: Helsinki University of Technology, 2004 (citado na pg. 28).

[DeepSeek-AI *et al.* 2025] DeepSeek-AI *et al. DeepSeek-V3 Technical Report*. 2025. arXiv: 2412.19437 [cs.CL]. url: https://arxiv.org/abs/2412.19437 (citado na pg. 7).

[Devlin *et al.* 2018] Jacob Devlin, Ming-Wei Chang, Kenton Lee e Kristina Toutanova. "Bert: pre-training of deep bidirectional transformers for language understanding". *arXiv preprint arXiv:1810.04805* (2018) (citado nas pgs. 1, 3, 7, 9, 10, 17, 19).

[E. R. Fonseca *et al.* 2016] Erick Rocha Fonseca, Leandro Borges dos Santos, Marcelo Criscuolo e Sandra Maria Aluísio. "Visao geral da avaliação de similaridade semântica e inferência textual". *Linguamática* 8.2 (2016), pp. 3–13 (citado na pg. 32).

[Geng e H. Liu 2023] Xinyang Geng e Hao Liu. *Openllama: an open reproduction of llama*. Mai. de 2023. url: https://github.com/openlm-research/open_llama (citado na pg. 10).

[Gomes *et al.* 2024] Luís Gomes, António Branco, João Silva, João Rodrigues e Rodrigo Santos. "Open sentence embeddings for portuguese with the serafim pt* encoders family". In: *Progress in Artificial Intelligence*. Cham: Springer Nature Switzerland, 2024, pp. 267–279. isbn: 978-3-031-73503-5. doi: doi.org/10.1007/978-3-031-73503-5_22 (citado na pg. 9).

[Gonçalves 2019] Carlos Alexandre. Gonçalves. *Morfologia*. 1a edição. Parábola, 2019, p. 165. isbn: 9788579341618 (citado nas pgs. 11–13).

[He, Gao *et al.* 2021] Pengcheng He, Jianfeng Gao e Weizhu Chen. *DeBERTaV3: Improving DeBERTa using ELECTRA-Style Pre-Training with Gradient-Disentangled Embedding Sharing*. 2021. arXiv: 2111.09543 [cs.CL] (citado nas pgs. 8, 9).

[He, X. Liu *et al.* 2021] Pengcheng He, Xiaodong Liu, Jianfeng Gao e Weizhu Chen. "Deberta: decoding-enhanced bert with disentangled attention". In: *International Conference on Learning Representations*. 2021. url: https://openreview.net/forum?id=XPZIaotutsD (citado nas pgs. 8, 41).

[Hedderich *et al.* 2021] Michael A. Hedderich, Lukas Lange, Heike Adel, Jannik Strötgen e Dietrich Klakow. "A survey on recent approaches for natural language processing in low-resource scenarios". In: *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, 2021, pp. 2545–2568. doi: 10.18653/v1/2021.naacl-main.201. url: https://aclanthology.org/2021.naacl-main.201 (citado na pg. 8).

[Hofmann *et al.* 2021] Valentin Hofmann, Janet Pierrehumbert e Hinrich Schütze. "Superbizarre is not superb: derivational morphology improves BERT's interpretation of complex words". In: *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 3594–3608. doi: 10.18653/v1/2021.acl-long.279. url: https://aclanthology.org/2021.acl-long.279/ (citado nas pgs. i, iii, 2, 3, 10, 14, 15, 29, 35).

[Howard e Ruder 2018] Jeremy Howard e Sebastian Ruder. "Universal language model fine-tuning for text classification". *arXiv preprint arXiv:1801.06146* (2018) (citado nas pgs. 6, 9).

[Hu *et al.* 2021] Edward J. Hu *et al. LoRA: Low-Rank Adaptation of Large Language Models*. 2021. arXiv: 2106.09685 [cs.CL]. url: https://arxiv.org/abs/2106.09685 (citado na pg. 9).

[Johnson *et al.* 2017] Melvin Johnson *et al.* "Google's multilingual neural machine translation system: enabling zero-shot translation". *Transactions of the Association for Computational Linguistics* 5 (2017), pp. 339–351. issn: 2307-387X. doi: 10.1162/tacl_a_00065. url: https://doi.org/10.1162/tacl%5C_a%5C_00065 (citado na pg. 8).

[Jones 1994] Karen Sparck Jones. "Natural language processing: a historical review". In: Springer Netherlands, 1994. doi: 10.1007/978-0-585-35958-8_1 (citado na pg. 5).

[Joshi *et al.* 2020] Pratik Joshi, Sebastin Santy, Amar Budhiraja, Kalika Bali e Monojit Choudhury. "The state and fate of linguistic diversity and inclusion in the NLP world". In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020, pp. 6282–6293. doi: 10.18653/v1/2020.acl-main.560. url: https://aclanthology.org/2020.acl-main.560 (citado nas pgs. 8, 9).

[Jurafsky e Martin 2024] Daniel Jurafsky e James H. Martin. *Speech and Language Processing*. 3a edição. 2024. url: https://web.stanford.edu/~jurafsky/slp3/ (citado nas pgs. 1, 11, 15).

[Kalai *et al.* 2025] Adam Tauman Kalai, Ofir Nachum, Santosh S. Vempala e Edwin Zhang. *Why Language Models Hallucinate*. 2025. arXiv: 2509.04664 [cs.CL]. url: https://arxiv.org/abs/2509.04664 (citado na pg. 9).

[Kaplan *et al.* 2020] Jared Kaplan *et al.* "Scaling laws for neural language models". *arXiv preprint arXiv:2001.08361* (2020) (citado nas pgs. 7, 8, 43).

[Kirov *et al.* 2018] Christo Kirov *et al.* "UniMorph 2.0: Universal Morphology". In: *Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)*. European Language Resources Association (ELRA), mai. de 2018. URL: https://aclanthology.org/L18-1293/ (citado na pg. 22).

[Kudo 2018] Taku Kudo. "Subword regularization: improving neural network translation models with multiple subword candidates". In: *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2018, pp. 66–75. DOI: 10.18653/v1/P18-1007. URL: https://aclanthology.org/P18-1007 (citado nas pgs. i, iii, 2, 3, 10, 15, 18, 35).

[Kudo e Richardson 2018] Taku Kudo e John Richardson. "SentencePiece: a simple and language independent subword tokenizer and detokenizer for neural text processing". In: *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Association for Computational Linguistics, nov. de 2018, pp. 66–71. DOI: 10.18653/v1/D18-2012. URL: https://aclanthology.org/D18-2012/ (citado na pg. 15).

[Kyjánek *et al.* 2020] Lukás Kyjánek, Zdenek Zabokrtskỳ, Magda Sevcikova e Jonás Vidra. "Universal derivations 1.0, a growing collection of harmonised word-formation resources." *Prague Bull. Math. Linguistics* 115 (2020), pp. 5–30 (citado na pg. 23).

[Lan *et al.* 2019] Zhenzhong Lan *et al.* "Albert: a lite bert for self-supervised learning of language representations". *arXiv preprint arXiv:1909.11942* (2019) (citado na pg. 8).

[Larcher *et al.* 2023] Celio Larcher *et al. Cabrita: closing the gap for foreign languages*. 2023. arXiv: 2308.11878 [cs.CL]. URL: https://arxiv.org/abs/2308.11878 (citado na pg. 10).

[Leminen *et al.* 2019] Alina Leminen, Eva Smolka, Jon A. Duñabeitia e Christos Pliatsikas. "Morphological processing in the brain: the good (inflection), the bad (derivation) and the ugly (compounding)". *Cortex* 116 (2019), pp. 4–44. ISSN: 0010-9452. DOI: https://doi.org/10.1016/j.cortex.2018.08.016. URL: https://www.sciencedirect.com/science/article/pii/S0010945218302661 (citado nas pgs. 2, 10, 14).

[Li *et al.* 2019] Xiaoya Li *et al.* "Is word segmentation necessary for deep learning of Chinese representations?" In: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2019. DOI: 10.18653/v1/P19-1314. URL: https://aclanthology.org/P19-1314 (citado na pg. 2).

[Y. Liu *et al.* 2019] Yinhan Liu *et al.* "Roberta: a robustly optimized bert pretraining approach". *arXiv preprint arXiv:1907.11692* (2019) (citado na pg. 7).

[Luong *et al.* 2015] Thang Luong, Hieu Pham e Christopher D. Manning. "Effective approaches to attention-based neural machine translation". In: *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2015, pp. 1412–1421. doi: 10.18653/v1/D15-1166 (citado na pg. 6).

[Mello *et al.* 2024] Guilherme Lamartine de Mello *et al.* "Pelle: encoder-based language models for brazilian portuguese based on open data". *arXiv preprint arXiv:2402.19204* (2024) (citado na pg. 9).

[Metheniti e Neumann 2020] Eleni Metheniti e Guenter Neumann. "Wikinflection corpus: a (better) multilingual, morpheme-annotated inflectional corpus". In: *Proceedings of the Twelfth Language Resources and Evaluation Conference*. European Language Resources Association, mai. de 2020, pp. 3905–3912. isbn: 979-10-95546-34-4. url: https://aclanthology.org/2020.lrec-1.481/ (citado na pg. 22).

[Mikolov *et al.* 2013] Tomas Mikolov, Kai Chen, Greg Corrado e Jeffrey Dean. "Efficient estimation of word representations in vector space". *arXiv preprint arXiv:1301.3781* (2013) (citado na pg. 5).

[Mota *et al.* 2016] Cristina Mota, Paula Carvalho e Anabela Barreiro. "Port4NooJ v3.0: integrated linguistic resources for Portuguese NLP". In: *Proceedings of the Tenth International Conference on Language Resources and Evaluation (LREC'16)*. European Language Resources Association (ELRA), mai. de 2016, pp. 1264–1269 (citado na pg. 3).

[Nivre *et al.* 2020] Joakim Nivre *et al.* "Universal Dependencies v2: an evergrowing multilingual treebank collection". In: *Proceedings of the Twelfth Language Resources and Evaluation Conference*. European Language Resources Association, mai. de 2020, pp. 4034–4043. isbn: 979-10-95546-34-4. url: https://aclanthology.org/2020.lrec-1.497/ (citado na pg. 23).

[Otter *et al.* 2021] Daniel W. Otter, Julian R. Medina e Jugal K. Kalita. "A survey of the usages of deep learning for natural language processing". *IEEE Transactions on Neural Networks and Learning Systems* 32 (2 fev. de 2021), pp. 604–624. issn: 2162-237X. doi: 10.1109/TNNLS.2020.2979670. url: https://ieeexplore.ieee.org/document/9075398/ (citado nas pgs. 5, 7).

[Paiva *et al.* 2014] Valeria de Paiva, Livy Real, Alexandre Rademaker e Gerard de Melo. "NomLex-PT: a lexicon of Portuguese nominalizations". In: *Proceedings of the Ninth International Conference on Language Resources and Evaluation (LREC'14)*. European Language Resources Association (ELRA), mai. de 2014, pp. 2851–2858. url: https://aclanthology.org/L14-1025/ (citado na pg. 23).

[Pennington *et al.* 2014] Jeffrey Pennington, Richard Socher e Christopher D Manning. "Glove: global vectors for word representation". In: *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*. 2014, pp. 1532–1543 (citado na pg. 5).

[Peters *et al.* 2018] Matthew E. Peters *et al.* "Deep contextualized word representations". In: *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*. Association for Computational Linguistics, 2018, pp. 2227–2237 (citado na pg. 5).

[R. Pires *et al.* 2023] Ramon Pires, Hugo Abonizio, Thales Sales Almeida e Rodrigo Nogueira. "Sabiá: portuguese large language models". In: *Intelligent Systems*. Springer Nature Switzerland, 2023, pp. 226–240. isbn: 9783031453922. doi: 10.1007/978-3-031-45392-2_15. url: http://dx.doi.org/10.1007/978-3-031-45392-2_15 (citado na pg. 10).

[T. Pires *et al.* 2019] Telmo Pires, Eva Schlinger e Dan Garrette. "How multilingual is multilingual bert?" In: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. 2019, pp. 4996–5001 (citado na pg. 8).

[Plag 2018] Ingo Plag. *Word-formation in English*. Cambridge university press, 2018 (citado nas pgs. 2, 10, 11, 14, 15).

[Radford, Narasimhan *et al.* 2018] Alec Radford, Karthik Narasimhan, Tim Salimans e Ilya Sutskever. "Improving language understanding by generative pre-training" (2018) (citado na pg. 7).

[Radford, Wu *et al.* 2019] Alec Radford, Jeff Wu *et al.* "Language models are unsupervised multitask learners" (2019) (citado nas pgs. 10, 18, 19, 37).

[Real, E. Fonseca *et al.* 2020] Livy Real, Erick Fonseca e Hugo Gonçalo Oliveira. "The assin 2 shared task: a quick overview". In: *International Conference on Computational Processing of the Portuguese Language*. Springer. 2020, pp. 406–412 (citado na pg. 32).

[Real, A. Rodrigues *et al.* 2018] Livy Real, Ana Rodrigues *et al.* "Sick-br: a portuguese corpus for inference". In: *International Conference on Computational Processing of the Portuguese Language*. Springer. 2018, pp. 303–312 (citado na pg. 32).

[J. Rodrigues *et al.* 2023] João Rodrigues *et al.* "Advancing neural encoding of portuguese with transformer albertina pt". In: *EPIA Conference on Artificial Intelligence*. Springer. 2023, pp. 441–453 (citado nas pgs. 9, 41).

[Ruder *et al.* 2019] Sebastian Ruder, Matthew E Peters, Swabha Swayamdipta e Thomas Wolf. "Transfer learning in natural language processing". In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Tutorials*. Association for Computational Linguistics, 2019, pp. 15–18. doi: 10.18653/v1/N19-5004 (citado na pg. 7).

[Sanh *et al.* 2019] Victor Sanh, Lysandre Debut, Julien Chaumond e Thomas Wolf. "Distilbert, a distilled version of BERT: smaller, faster, cheaper and lighter". *CoRR* abs/1910.01108 (2019). arXiv: 1910.01108. url: http://arxiv.org/abs/1910.01108 (citado na pg. 7).

[Santos, J. Rodrigues *et al.* 2024] Rodrigo Santos, João Rodrigues *et al. Fostering the Ecosystem of Open Neural Encoders for Portuguese with Albertina PT-* family*. 2024. arXiv: 2403.01897 [cs.CL] (citado nas pgs. 9, 41).

[Santos, Silva *et al.* 2024] Rodrigo Santos, João Silva, Luís Gomes, João Rodrigues e António Branco. *Advancing Generative AI for Portuguese with Open Decoder Gervásio PT-**. 2024. arXiv: 2402.18766 [cs.CL] (citado na pg. 10).

[Schuck *et al.* 2025] André da Fonseca Schuck, Gabriel Lino Garcia, João Renato Ribeiro Manesco, Pedro Henrique Paiola e João Paulo Papa. "Evaluating large language models for brazilian portuguese sentiment analysis: a comparative study of multilingual state-of-the-art vs. brazilian portuguese fine-tuned llms". *Journal of the Brazilian Computer Society* 31.1 (out. de 2025), pp. 885–917. doi: 10.5753/jbcs.2025.5793. url: https://journals-sol.sbc.org.br/index.php/jbcs/article/view/5793 (citado na pg. 9).

[Schuster e Nakajima 2012] Mike Schuster e Kaisuke Nakajima. "Japanese and korean voice search". In: *2012 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2012, pp. 5149–5152. doi: 10.1109/ICASSP.2012.6289079 (citado nas pgs. i, iii, 10, 15, 16).

[Sennrich *et al.* 2016] Rico Sennrich, Barry Haddow e Alexandra Birch. "Neural machine translation of rare words with subword units". In: *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2016, pp. 1715–1725. doi: 10.18653/v1/P16-1162. url: https://aclanthology.org/P16-1162 (citado nas pgs. i, iii, 10, 15, 17).

[Souza *et al.* 2020] Fábio Souza, Rodrigo Nogueira e Roberto Lotufo. "Bertimbau: pretrained bert models for brazilian portuguese". In: *Intelligent Systems*. Springer International Publishing, 2020, pp. 403–417 (citado na pg. 9).

[Sun *et al.* 2025] Yutao Sun *et al.* "Efficient attention mechanisms for large language models: a survey". *arXiv preprint arXiv:2507.19595* (2025) (citado na pg. 8).

[Sutskever *et al.* 2014] Ilya Sutskever, Oriol Vinyals e Quoc V Le. "Sequence to sequence learning with neural networks". In: *Advances in Neural Information Processing Systems*. Vol. 27. 2014, pp. 3104–3112 (citado na pg. 6).

[Touvron *et al.* 2023] Hugo Touvron *et al. LLaMA: Open and Efficient Foundation Language Models*. 2023. arXiv: 2302.13971 [cs.CL]. url: https://arxiv.org/abs/2302.13971 (citado na pg. 10).

[Vargas *et al.* 2022] Francielle Vargas, Isabelle Carvalho, Fabiana Rodrigues de Góes, Thiago Pardo e Fabrício Benevenuto. "HateBR: a large expert annotated corpus of Brazilian Instagram comments for offensive language and hate speech detection". In: *Proceedings of the Thirteenth Language Resources and Evaluation Conference*. Marseille, France: European Language Resources Association, jun. de 2022, pp. 7174–7183. url: https://aclanthology.org/2022.lrec-1.777/ (citado nas pgs. 33, 34).

[Vaswani *et al.* 2017] Ashish Vaswani *et al.* "Attention is all you need". In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017 (citado nas pgs. 1, 6, 19, 41).

[Virtanen *et al.* 2019] Antti Virtanen *et al. Multilingual is not enough: BERT for Finnish*. 2019. arXiv: 1912.07076 [cs.CL]. url: https://arxiv.org/abs/1912.07076 (citado na pg. 9).

[Wagner Filho *et al.* 2018] Jorge A. Wagner Filho, Rodrigo Wilkens, Marco Idiart e Aline Villavicencio. "The brWaC corpus: a new open resource for Brazilian Portuguese". In: *Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)*. European Language Resources Association (ELRA), 2018 (citado na pg. 9).

[Wang e Komatsuzaki 2021] Ben Wang e Aran Komatsuzaki. *GPT-J-6B: A 6 Billion Parameter Autoregressive Language Model*. https://github.com/kingoflolz/mesh-transformer-jax. Mai. de 2021 (citado na pg. 10).

[Xue *et al.* 2021] Linting Xue *et al.* "MT5: a massively multilingual pre-trained text-to-text transformer". In: *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Online: Association for Computational Linguistics, jun. de 2021, pp. 483–498. doi: 10.18653/v1/2021.naacl-main.41. url: https://aclanthology.org/2021.naacl-main.41/ (citado na pg. 9).

[Yang *et al.* 2025] An Yang *et al. Qwen3 Technical Report*. 2025. arXiv: 2505.09388 [cs.CL]. url: https://arxiv.org/abs/2505.09388 (citado nas pgs. 19, 41).

[Young *et al.* 2018] Tom Young, Devamanyu Hazarika, Soujanya Poria e Erik Cambria. "Recent trends in deep learning based natural language processing". *IEEE Computational Intelligence Magazine* 13 (3 ago. de 2018), pp. 55–75. issn: 1556-603X. doi: 10.1109/MCI.2018.2840738. url: https://ieeexplore.ieee.org/document/8416973/ (citado na pg. 5).